## Université de Montréal

# Diffusion de modules compilés pour le langage distribué Termite Scheme

par

## Frédéric Hamel

Département d'informatique et recherche opérationnelle Faculté des arts et des sciences

Mémoire présenté en vue de l'obtention du grade de Maître ès sciences (M.Sc.) en Informatique

March 2, 2020

## Université de Montréal

Faculté des études supérieures et postdoctorales

Ce mémoire intitulé

## Diffusion de modules compilés pour le langage distribué Termite Scheme

présenté par

## Frédéric Hamel

a été évalué par un jury composé des personnes suivantes :

Michail Famelis

(président-rapporteur)

Marc Feeley

(directeur de recherche)

Stafan Monnier
(membre du jury)

### Résumé

Ce mémoire décrit et évalue un système de module qui améliore la migration de code dans le langage de programmation distribuée Termite Scheme. Ce système de module a la possibilité d'être utilisé dans les applications qu'elles soient distribuées ou pas. Il a pour but de faciliter la conception des programmes dans une structure modulaire et faciliter la migration de code entre les nœuds d'un système distribué. Le système de module est conçu pour le système Gambit Scheme, un compilateur et interprète du langage Scheme utilisé pour implanter Termite. Le système Termite Scheme est utilisé pour implémenter les système distribué.

Le problème qui est résolu est la diffusion de code compilé entre les nœuds d'un système distribué quand le nœud destination n'a aucune connaissance du code qu'il reçoit. Ce problème est difficile, car les nœuds ne sont pas homogènes, ils ont différentes architectures (x86, ARM).

Notre approche permet d'identifier les modules de façon unique dans un contexte distribué. La facilité d'utilisation et la portabilité ont été des facteurs importants dans la conception du système de module.

Le mémoire décrit la structure des modules, leur implémentation dans Gambit et leur application. Les qualités du système de module sont démontrées par des exemples et la performance est évaluée expérimentallement.

Mots clés: Programmation fonctionnelle, Scheme, Erlang, Système de module, Système distribué, Agent mobile.

## Summary

This thesis presents a module system for Termite Scheme that supports distributed computing. This module system facilitates application modularity and eases code migration between the nodes of a distributed system. This module system also works for developing non-distributed applications. The Gambit Scheme system is used to implement the distributed Termite and the Module system.

The problem that is solved is the migration of compiled code between nodes of a distributed system when the receiving node has no knowledge of the code. This is a challenging problem because the nodes are not homogenous, they have different architectures (ARM, x86).

Our approach uses a naming model for the modules that uniquely identifies in a distributed context. Both ease of use and portability were important factors in the design of the module system.

The thesis describes a module system and how it was integrated into Gambit. The system allows developing distributed modular system. The features of this system are shown through application examples and the performance is evaluated experimentally.

**Keywords**: Functional programming, Scheme, Erlang, Module System, Distributed System, Mobile Agent.

## Table des matières

Résumé	3
Summary	4
Liste des figures	9
Liste des sigles et des abréviations	13
Remerciements	14
Chapitre 1. Modularisation des systèmes distribués	15
1.1. Déploiement	15
1.2. Systèmes distribués	16
1.3. Modules versionnés	17
1.4. Code mobile	18
1.5. Survol	19
Chapitre 2. Bibliothèques Scheme	20
2.1. Scheme et sa syntaxe	20
2.2. Procédures et macros	22
2.3. Structure des bibliothèques	24
2.4. La syntaxe de Termite	28
2.5. Conclusion	30
Chapitre 3. Implémentation des modules	31

3.1. La notation des fichiers dans Gambit	32
3.2. La forme ##namespace	32
11 0	
3.3.1. Les méta informations	35
3.4. Implémentation des modules primitifs	35
3.4.1. La forme ##import	36
3.5. Implémentation des modules R7RS	37
3.5.1. Expansion du import	37
3.5.1.1. Importation d'un module primitif	37
3.5.1.2. Importation d'un module R7RS	38
3.5.2. Expansion du define-library	39
3.5.2.1. Extensions de Gambit	41
3.6. Conclusion	42
Chapitre 4. Modèle de chargement	43
4.1. Chargement des bibliothèques	43
4.2. Modèle statique	44
4.3. Modèle dynamique	45
4.3.1. Module compilé dans Gambit	47
4.4. Module hébergé	47
4.4.1. Installation automatique	48
4.5. Conclusion	49
Chapitre 5. Gestion des modules	51
5.1. Sommaire	51

5.2.1. Installation des packages et des modules	53
5.3. Désinstallation	55
5.4. Mise à jour	55
5.5. Tests unitaires	56
5.6. Compilation d'un module	56
5.7. Comparaison avec d'autres systèmes	57
5.7.1. Organisation de OCaml	57
5.7.2. Organisation de Python	58
5.7.3. Organisation de NodeJS	59
5.7.4. Organisation de Java	59
5.7.5. Organisation de Go	60
5.8. Conclusion	60
Chapitre 6. Migration de code	63
6.1. Systèmes distribués	63
6.2. Communication dans Termite	64
6.3. <i>Hook</i> des procédures inconnues	65
6.4. Exemple de migration de code	66
6.5. Conclusion	67
Chapitre 7. Évaluation	70
7.1. Description des expériences	70
7.2. Spécification des machines	71
7.3. Résultats	72
7.3.1. Comparaison entre les scénarios INTERPRETED et STEADY-STATE	

7.3.2. Comparaison entre les scénarios INTERPRETED et FIRST-INSTALL	73
7.4. Conclusion	74
Chapitre 8. Conclusion	76
Références bibliographiques	79
Annexe A. Information des environnement de test	81

# Liste des figures

2.1	Programme Scheme qui imprime la factorielle de 100	22
2.2	Exemple de boucle affiche n fois le message msg qui utilise des appels terminaux	
	lors de l'appel de repeat et newline	23
2.3	Implémentation de la macro include qui permet l'inclusion d'un fichier dans un	
	autre fichier avec la forme define-macro	23
2.4	Implémentation de la macro include qui permet l'inclusion d'un fichier dans un	
	autre fichier avec la forme define-syntax	24
2.5	Le fichier fact.scm est un exemple de module R4RS exposant la fonction	
	mathématique fact. Le fichier main.scm est un programme principal qui utilise	
	le module fact.scm	26
2.6	Structure globale d'un module R6RS	26
2.7	Structure globale d'un module R7RS	27
2.8	Un serveur Ping-Pong en Termite Scheme	29
3.1	Namespace Global	33
3.2	Namespace Set	33
3.3	Namespace Rename	33
3.4	Module Hello	34
3.5	Syntaxe des formes demand-module et supply-module	34
3.6	Écriture d'un module qui implémente des fonctions de conversions entre les	
	angles en degrés et en radian. Ce module est séparé en 2 fichiers. Le fichier	
	angle2/angle2#.scm contient les exportations et angle2/angle2.scm contient	
	l'implémentation des fonctions.	36

3.7	Expansion de (##import angle2)	37
3.8	Expansion du import d'un module primitif	38
3.9	L'exemple de l'expansion du import du module R7RS github.com/gambit/hello	
	qui exporte les procédures hi et salut.	39
3.10	Différents ##namespace générés par l'expansion du import d'un module R7RS	39
3.11	Le code source du module github.com/gambit/hello avant l'expansion	40
3.12	Expansion de la forme define-library du module github.com/gambit/hello	40
3.13	Exemple d'importation relative du module	41
3.14	Implémentation de la bibliothèque système (scheme case-lambda)	41
4.1	Un exemple qui montre la collection des modules à partir du module _zlib suivit de l'initialisation des modules collectés. La collection des modules est effectuée par la procédure ##collect-modules. L'ensemble des modules retournés sont initialisés par la procédure ##init-modules. Les enregistrements des modules	
	_zlib et _digest ont été ajoutés à la liste des modules enregistrés (variable ##registered-modules)	46
4.2	Un exemple d'un système fictif composé de différents modules. Le module principal se nomme main.scm avec l'extension .scm et les bibliothèques ont l'extension .sld	46
4.9		40
4.3	Un module qui implémente la fonction mathématique fib au niveau principal («top level»)	47
4.4	Grammaire EBNF représentant un hostname selon un sous-ensemble du RFC-	
	2396	48
4.5	Exemples de manipulation de la <i>whitelist</i> par les arguments de la ligne de commande. Le premier exemple montre le rejet de l'installation, car le module n'est pas dans la <i>whitelist</i> . Le second exemple permet les modules sous github.com/feeley d'être installé automatiquement. Le dernier exemple montre	
	comment désactiver l'installation automatique en vidant la whitelist	49

4.6	L'exemple montre le résultat d'une réponse négative lors de l'installation du	
	module qui n'est pas dans la <i>whitelist</i> . Il ne se fait pas installer	50
5.1	Grammaire formelle d'un module-ref	52
5.2	Exemple d'installation d'un package hébergé dans le préfixe d'installation par	
	défaut	54
5.3	Exemple d'installation d'un package hébergé dans le préfixe d'installation	
	/tmp/exemple	54
5.4	Exemple d'installation d'un $package$ dans le préfixe d'installation $/ tmp/exemple$	
	à partir du répertoire local /local/dir/	55
5.5	Une table qui compare différents systèmes de module sur la capacité d'installer	
	plusieurs versions d'un module. Le système Go permet plusieurs versions d'un	
	module pour des versions incompatibles selon le sémantique de version. La version	
	1.0.0 coexiste avec la version 2.0.0. La version récente 1.2.0 remplace la vieille	
	version 1.0.1	58
5.6	L'ensemble des répertoires qui est utilisé par Python version 3.7 pour organiser	
	les bibliothèques sur un système de type Linux	59
5.7	Exemple d'importation de la version v3 du module pkg en utilisant le service	
	gopkg.in	60
5.8	Un exemple qui montre l'importation de deux versions d'un même module en Go.	
	Le module <b>go-hello</b> version 2 exporte la fonction Salut qui n'existe pas dans la	
	version 1	61
5.9	Arborescence des fichiers dans le gopath	62
6.1	La représentation du résultat de la sérialisation en u8vector de la procédure sqrt.	65
6.2	Le code du serveur qui configure la $hook$ qui résout les références	
	à des procédures inconnues. C'est effectué avec la procédure	
	##unknown-procedure-handler-set!	67
6.3	Extrait du code de l'horloge programmable.	68

6.4	Les applications clients qui interragissent avec l'horloge programmable. Il	
	y a le programme qui modifit le timezone de l'horloge programme dans	
	timezone-set.scm. Il y a le programme de mise à jour de l'horloge programmable	
	dans updater.scm	69
7.1	Les temps le scénario INTERPRETED avec $x86/macOS$ ou $ARM/Linux$ comme	
	le nœud de départ	73
7.2	Les temps dans le scénario STEADY-STATE avec $x86/macOS$ ou $ARM/Linux$	
	comme le nœud de départ	73
7.3	Les temps dans les scénario FIRST-INSTALL avec $x86/macOS$ ou $ARM/Linux$	
	comme le nœud de départ	74
A.1	La spécification de la machine arctic qui est utilisé comme nœud de destination	
	dans l'ensemble des tests. Cette machine, nommé $x86/Linux$ est refroidit au	
	liquide	81
A.2	La spécification du CPU du Raspberry Pi $ARM/Linux$ utilisé dans les tests	82
A 3	La spécification de la machine $x86/macOS$ qui roule mac OS	82

## Liste des sigles et des abréviations

FFI Interface de fonction étrangère (Foreign Function Interface)

REPL Boucle de lecture et d'évaluation (Read Eval Print Loop)

RPC Appel de procédure à distance (Remote Procedure Call)

### Remerciements

Je voudrais remercier mon directeur Marc Feeley pour l'inspiration, les précieux conseils et le support qu'il m'a fournis.

Merci à ma famille, qui a toujours été là pour moi tant dans les moments faciles et difficiles. Mon père Gérald et ma mère Sylvie mon supporté et encouragé durant mon parcours académique. Mon frère Alex qui m'a aussi encouragé. Merci à ma tante Jocelyne, qui m'a appris le piano et appris la confiance en soi. Merci à mes neveux Thomas et William pour leur présence et amour. J'ai la chance exceptionnelle de les côtoyer et de pouvoir enrichir et m'inspirer d'eux.

Mes amis ont une place importante dans ma vie, ils m'ont aidé à avancer dans la vie. Entre autres, je remercie Aldo Lamarre, Sébastien Richer, Abdel et les gens de l'association d'informatique pour les discussions intéressantes. Merci aux personnes que j'ai pu rencontrer au piano publique, qui mon données l'énergie de continuer.

## Chapitre 1

## Modularisation des systèmes distribués

Les programmes modernes ont une structure *modulaire*, c'est-à-dire que leur code se décompose logiquement en différentes parties relativement indépendantes, les *modules*. Cette structure a de nombreux avantages, entre autres sur les plans du développement, la maintenance et le déploiement des programmes. Ce mémoire porte sur la modularité dans le contexte des systèmes distribués où le calcul est réparti sur de multiples ordinateurs reliés en réseau. Ce contexte pose des défis particuliers de déploiement.

### 1.1. Déploiement

Le déploiement d'un programme c'est sa mise en service pour qu'il soit utilisable. Ça consiste à installer une forme exécutable du programme sur le(s) ordinateur(s) de sorte à pouvoir l'exécuter. La façon de diffuser les modules, les stocker sur disque, les charger en mémoire, etc. peut prendre plusieurs formes.

Un programme sous forme monolithique contient dans son code exécutable toutes les instructions exécutées par l'ordinateur. Cette forme était la norme dans les premiers systèmes informatiques, et l'est toujours pour les systèmes embarqués qui n'ont pas de système d'exploitation indépendant. Lorsqu'un système d'exploitation est disponible sur l'ordinateur on peut le considérer comme étant un module puisqu'il offre des services précis avec une interface standardisée. Dans ce cas, un programme peut prendre la forme d'un seul fichier de code qui, à son exécution, communiquera avec le système d'exploitation pour accéder à ses services. Ce genre de fichier exécutable est obtenu par une édition de liens statique qui combine en un seul fichier tous les modules (à l'exception du système d'exploitation). Par rapport à la forme monolithique, cette organisation simplifie le développement, car le

programmeur n'a pas à se soucier du développement des services de base comme l'accès aux fichiers, la gestion des processus et de la mémoire, etc. Le programme peut être diffusé à d'autres ordinateurs ayant le même système d'exploitation simplement en y transférant le fichier exécutable.

L'édition de lien statique a un certain nombre de défauts. L'état des modules utilisés au moment de l'édition de liens est figé au sein du programme, ce qui empêche la mise à jour individuelle des modules à de nouvelles versions. Il faut recompiler tous les modules qui ont subi une mise à jour et refaire l'édition de liens du programme principal. Le coût en temps et l'effort pour un petit changement sont importants. Le chapitre 4 va détailler plus en profondeur ces problèmes.

L'édition de liens peut se faire paresseusement par le système d'exploitation à l'exécution du programme, ce qu'on appelle l'édition de liens dynamiques. Cela permet de garder la structure modulaire au déploiement. Chaque module est une composante séparée du programme principal. Ces modules sont lus du disque et chargés en mémoire durant l'exécution du programme. Ce chargement est effectué par l'éditeur de liens dynamique du système d'exploitation [2, 14] qui s'occupe de lier les fonctionnalités des modules au programme principal. L'avantage principal du chargement dynamique de module est la possibilité de mise à jour individuelle d'un module sans avoir à lier le programme principal; dans le modèle statique, le programme principal doit être lié à nouveau avec les modules. Les modules chargés dynamiquement par le système d'exploitation peuvent être partagés entre différents programmes.

## 1.2. Systèmes distribués

Un système distribué est un groupe d'ordinateurs, les nœuds de calcul, reliés en réseau afin qu'ils puissent échanger des messages et coordonner leurs activités. Chaque nœud peut exécuter le même code que les autres nœuds ou bien un code spécialisé au rôle qu'il joue au sein du système (e.g. serveur vs client). D'une façon ou de l'autre on parlera de l'ensemble du code comme étant le programme distribué qu'ils exécutent.

Les programmes distribués posent de nouveaux problèmes de déploiement, car les nœuds sont rarement identiques. Ils peuvent avoir des architectures matérielles différentes, et/ou des ressources et périphériques différents, et/ou des systèmes d'exploitation différents. Il

est à noter que ces caractéristiques peuvent changer pendant la période d'exploitation du programme, par exemple lors de mise à jour du matériel et du système d'exploitation. Ce problème est exacerbé par le code mobile, c'est-à-dire un calcul en exécution sur un nœud qui se déplace, ou migre, sur un autre nœud pour poursuivre son exécution. Cette migration de tâche est utile pour améliorer la performance lorsque le nœud destinataire est plus puissant ou possède localement les données utilisées par la tâche migrée. Finalement, dans le cas de programmes distribués offrant un service à l'externe, on veut minimiser les interruptions de service causées par les mises à jour du système ou d'une de ses parties, que ce soit 1) au niveau matériel et/ou le système d'exploitation ou 2) le programme distribué lui-même. Dans le premier cas, la migration de tâche peut être utilisée pour migrer le service à un autre nœud le temps que se fasse la mise à jour. Dans le deuxième cas, on aimerait utiliser les nouveaux modules modifiés sans avoir à arrêter le programme et le redémarrer.

Il apparait donc avantageux que le code du programme distribué prenne une forme exécutable *portable* qui peut s'adapter aux particularités de chaque nœud sans demander au développeur de modifier ou recompiler le programme distribué. Idéalement, cette portabilité ne devrait pas causer des pertes de performance. D'autre part, la possibilité de substituer une version d'un module par une nouvelle version sans interruption du programme est attrayante.

#### 1.3. Modules versionnés

Nous définissons le terme version de module comme étant tout simplement un état de son code. Ainsi, lorsqu'on fait une modification au code d'un module pour corriger un problème ou pour étendre ses fonctionnalités on obtient une nouvelle version du module. La version d'un module est donc essentielle pour identifier son code, et donc sa fonctionnalité, de façon précise. Pour permettre plusieurs versions d'un module au sein d'un programme, il est important que chaque version des modules soit distinguable. Lors de la migration de code, il est possible que plusieurs versions d'un module soient chargées pour accéder des fonctionnalités.

Le concept de version de module n'est pas intégré à la sémantique de plusieurs langages de programmation. En Python et Java les modules sont référés dans le code avec un nom qui n'inclut pas la version. Go est exemple de langage de programmation qui permet d'inclure la version lorsqu'on réfère à un module.

Dans les systèmes qui considèrent chaque version d'un module comme un module différent, il devient possible d'écrire des programmes qui utilisent de multiples versions d'un module simultanément. Cela peut amener certains problèmes de conflit entre les versions. Ces conflits peuvent être observés dans les langages interprétés comme JavaScript ou dans les langages compilés comme C/C++. Les conflits peuvent être dans les noms des fonctions du module ou dans des variables globales partagées entre plusieurs versions du module.

#### 1.4. Code mobile

Dans un système distribué, il est utile d'amorcer des calculs sur un nœud à partir d'un autre. Cela peut se faire avec un appel RPC (Remote Procedure Call) ou par migration de tâches. Un appel RPC correspond à une requête d'exécution d'un calcul sur un nœud distant. Une migration de tâche copie l'état courant de la tâche et l'envoie sur le nœud distant où son exécution est continuée.

Les appels RPC sont présents dans plusieurs systèmes et langages de programmation. Le protocole ssh permet une forme d'appel RPC par invocation de processus sur un nœud distant. Java offre les appels distants par un mécanisme similaire au RPC nommé RMI (Remote Method Invocation). Le langage C offre des bibliothèques qui implémentent un protocole de RPC. Ces variantes de RPC sont limitées aux fonctionnalités fournies par le nœud distant. Pour le bon fonctionnement de cette approche, il est nécessaire que le service demandé soit déjà déployé sur la machine distante.

La migration de tâche permet de transférer une tâche d'un nœud à un autre. Ce mécanisme a été implémenté dans différents langages comme Erlang [21], Java [5], Scheme [27, 12], JavaScript [20]. Ce mécanisme requiert typiquement que l'ensemble du code soit disponible sur le nœud distant.

Un système écrit Java [5] est un exemple de migration de tâche. Il capture l'état présent du programme qui consiste aux valeurs et aux types de toutes les variables de chaque objet. La pile des appels de méthode avec les valeurs de toutes les variables est aussi incluse dans l'état du programme. Ces informations sont transmises au nœud distant qui les utilise pour reconstruire le programme initial. L'ensemble des méthodes sur le nœud de départ est présent sur le nœud d'arrivée.

Le système implémenté dans le langage de programmation Erlang [21] qui implémente des agents mobiles requiert que le code soit disponible sur le nœud destination.

Le système de migration en JavaScript [20] utilise des nœuds pour conserver le code. Il est basé sur le fait que le code des agents est connu par les nœuds spécialisés. Puisque le code des agents est connu, il suffit de transmettre l'état de l'agent pour effectuer une migration. Le scénario de migration de code présenté dans le chapitre 2 nous à inspiré dans la conception d'un système de module. Notre motivation est la migration de code entre des nœuds d'un système distribué comme présenté à la fin du chapitre 2. Nous avons développé un système de module pour le langage de programmation Scheme qui offre la possibilité de migrer un agent sur un nœud qui ne connait pas à priori le code de l'agent, et qui permet à des versions multiples d'un module de coexister.

Notre point de vue est que la migration de code ne devrait pas demander une préconfiguration des nœuds, car une gestion coordonnée de tous les nœuds d'un système distribué est difficile ou impossible lorsqu'il y a plusieurs nœuds et/ou des nœuds de nature différente et/ou il n'y a pas un gestionnaire unique de l'ensemble des nœuds. Même dans le cas où les nœuds sont sous le contrôle d'un unique gestionnaire, il serait avantageux de ne pas interrompre le fonctionnement du système distribué lorsque les modules sont améliorés.

Les contributions de se travail sont la conception d'un système de module pour les systèmes distribués et son intégration dans Gambit Scheme. Cela permet la diffusion des modules entre les nœuds d'un système distribué.

#### 1.5. Survol

Le chapitre 2 explique les approches existantes de modularisation en Scheme. Le chapitre 3 explique les problématiques des dépendances entre des modules natifs au sein du système de module. Le chapitre 4 traite de l'implémentation du système de module et son intégration dans Gambit, un compilateur/interprète performant pour Scheme. Le chapitre 5 explique les mécanismes de chargement des modules. Le chapitre 6 traite de la diffusion des modules et de la migration de tâche. Le chapitre 7 présente une évaluation du système de modules avec des résultats d'expériences effectuées entre des systèmes d'exploitation (SE) et architectures différentes.

## Chapitre 2

## Bibliothèques Scheme

Pour développer notre approche de modularisation dans le contexte de systèmes distribués nous avons choisi un langage de programmation nous permettant de facilement expérimenter avec le code mobile. Le langage de programmation Scheme a plusieurs implémentations, dont Gambit, Racket[23], Gerbil[28] et JazzScheme[6]. Le langage Termite Scheme [12], une variante de Scheme étendue avec des fonctionnalités de programmation distribuée inspirées du langage Erlang, nous est apparu comme une option intéressante vue sa performance, sa portabilité et son support pour la méta programmation facilitée par son homoiconicité. Il est implémenté en tant que module de Gambit. Notre travail a donc pu se concentrer sur la conception d'un système de module spécialisé aux besoins du code mobile. Le système Termite Scheme est expliqué sommairement dans le chapitre 6.

Ce chapitre introduit la syntaxe de Scheme et les différentes approches de modularisation existantes. Afin de faciliter son adoption, le système de module que nous avons développé se base sur ces approches de modularisation.

### 2.1. Scheme et sa syntaxe

Le langage Scheme [8], conçu en 1975 par Guy L. Steele et Gerald Jay Sussman, est une variante minimaliste de Lisp. Depuis sa conception, plusieurs normes ont vu le jour; les plus connues étant le R4RS (1991), R5RS (1998), R6RS (2007) et R7RS (2013). Notre implémentation utilise R7RS. Notre système de modules pourrait être conçu avec la syntaxe de R6RS. Il suffit que la structure des bibliothèques permette les noms uniques pour les modules.

Scheme est un langage de programmation avec un système de type dynamique. Les types sont associés aux valeurs plutôt qu'aux variables et une variable donnée n'est pas contrainte à contenir un type particulier. Il permet la programmation fonctionnelle, la programmation impérative et la méta programmation.

Sur le plan syntaxique, Scheme hérite la syntaxe préfixe parenthésée de Lisp. Un programme Scheme est une séquence de s-expressions (expressions symboliques). Chaque s-expression correspond soit à une constante, une variable ou une forme ( $\langle op \rangle \langle arg \rangle ...$ ) qui dénote un appel de procédure, un appel de macro, ou une forme spéciale.

Les formes syntaxiques spéciales de base en Scheme sont define, lambda, let, if et set!.

- La forme (define <name> <val>) associe le nom <name> avec la valeur de l'expression <val>. Il est utilisé pour définir les variables globales.
- La forme (lambda <params> <body>) permet la définition de procédures anonymes. Les paramètres sont <params> et le corps de la procédure est l'expression <body>.
- La forme (let *<bindings> <body>*) permet de créer des liaisons (*<bindings>*) visibles seulement dans le contexte de l'expression *<body>* dont la valeur de la forme let. Les liaisons sont sous la forme d'une liste associative nom et valeur.
- L'évaluation conditionnelle est obtenue par la forme (if  $\langle e1 \rangle$   $\langle e2 \rangle$   $\langle e3 \rangle$ ). L'expression  $\langle e3 \rangle$  est exécutée si la valeur de l'expression  $\langle e1 \rangle$  est fausse sinon l'expression  $\langle e2 \rangle$  est exécutée.
- La forme (set! <name> <val>) modifie le contenu de la variable <name> avec la valeur <val>.

À titre d'exemple, la figure 2.1 montre un programme Scheme simple avec deux définitions de fonctions.

Les différents types primitifs disponibles dans la norme Scheme sont boolean, pair, symbol, number, char, string, vector, port et procedure. Plusieurs systèmes Scheme offrent des extensions à ces types, tels les dictionnaires (hash tables), les structures (records) et tableaux numériques (par exemple Gambit offre le type u8vector qui est un tableau d'octets).

Fig. 2.1. Programme Scheme qui imprime la factorielle de 100.

#### 2.2. Procédures et macros

Les procédures sont des objets de première classe, c'est-à-dire pouvant être manipulées comme n'importe quel type de donnée. Elles peuvent être passées en tant que paramètre à une procédure et retournées en tant que résultat. Certaines procédures, comme for-each, map et fold, en tirent profit.

Les procédures sont définies par la forme lambda qui a une liste de paramètres et une séquence d'au moins une s-expression comme corps. Lors de l'appel d'une procédure, chacun des paramètres actuels est évalué puis propagé à la procédure. C'est un mode de passage de paramètre par valeur. Les boucles sont normalement exprimées sous la forme de récursion. Cela est facilité par l'existence de l'appel terminal [16] garanti, qui permet des récursions sans coût. L'appel terminal de procédure est simplement la dernière appel effectué dans une procédure. Ces appels n'ont pas besoin de retourner, ils permettent d'exprimer les boucles infinies souvent utilisées dans le contexte d'un serveur qui boucle sur les évènements. Par exemple, l'appel récursif de repeat dans la figure 2.2 est terminal, car l'appelant n'a pas besoin du résultat pour terminer, donc l'appelant peut donner le contrôle à la procédure. Sans les appels terminaux, les boucles infinies mèneraient à un débordement de la pile d'appels. Il est assez simple d'ajouter une syntaxe pour les boucles à l'aide de la méta programmation.

La méta programmation en Scheme est basée sur la capacité d'un programme de manipuler d'autres programmes comme des données. Cela implique qu'il est possible de générer,

Fig. 2.2. Exemple de boucle affiche n fois le message msg qui utilise des appels terminaux lors de l'appel de repeat et newline.

analyser et modifier le code d'un autre programme. Les constructions utilisées pour manipuler le code du programme et ajouter des extensions au langage sont les macros.

En C et C++, les macros sont basées sur un modèle de remplacement textuel simple et ne permettent pas de récursion. Un appel à la macro est remplacé par le corps de celleci. Les macros de style Lisp permettent des transformations qui se font avec l'ensemble des procédures du langage, ce qui leur donne plus de flexibilité. La différence entre les procédures et les macros est le mode de passage de paramètres. Les paramètres sont passés à la macro sans être évalués. Certaines implémentations de Scheme offrent la forme define-macro pour définir les macros. Cette forme est équivalente au defmacro de Lisp. Elle accepte en paramètre des s-expressions et retourne une s-expression.

Fig. 2.3. Implémentation de la macro include qui permet l'inclusion d'un fichier dans un autre fichier avec la forme define-macro.

Un exemple qui montre les capacités des macros Scheme est la macro include. Cette macro permet l'inclusion du contenu d'un fichier au point d'appel. Pour inclure un fichier

dans un autre, il faut tout d'abord lire le contenu du fichier à inclure. Ensuite, il suffit de retourner le code lu. La figure 2.3 montre une implémentation de cette macro avec define-macro. Pour les systèmes Scheme n'offrant pas la forme define-macro, il est assez simple d'implémenter la forme include avec define-syntax qui est une forme de définition de macro alternative à define-macro. L'implémentation de cette macro est donnée à la figure 2.4. Les particularités de define-syntax ne sont pas expliquées puisqu'elles ne sont pas pertinentes à ce mémoire.

Fig. 2.4. Implémentation de la macro include qui permet l'inclusion d'un fichier dans un autre fichier avec la forme define-syntax.

### 2.3. Structure des bibliothèques

Les bibliothèques, aussi appelées modules, facilitent le partage de fonctionnalités entre plusieurs programmes. Dans le standard R4RS[7] et R5RS[18] les modules consistent en des fichiers Scheme qui contiennent des définitions de procédures et de macros. Ils sont chargés dans l'environnement global par la procédure load. Certaines implémentations de Scheme ont la forme spéciale include qui permet de séparer un module Scheme en plusieurs parties. Cette forme peut s'ajouter facilement au langage (tel que montré à la figure 2.4). Le modèle de bibliothèque basé sur load et include possède plusieurs lacunes.

- Ce modèle de chargement n'est pas à l'abri des chargements multiples d'un module qui mène soit à de la duplication de code (dans le cas de la forme include) ou à de la réévaluation d'un code (dans le cas de load).
- Toutes les déclarations dans un module sont ajoutées à l'environnement global lors du chargement par load. Cela mène à des conflits de nom entre les identifiants du module principal et des modules importés.
- L'importation d'un module par load ou include nécessite la connaissance de son emplacement dans le système de fichier.

Le chargement d'un module dans Gambit Scheme par load se fait en plusieurs phases: l'analyse lexicale, l'analyse syntaxique, l'expansion de macro et l'évaluation. L'analyse lexicale brise l'expression en lexèmes. La séquence de lexèmes est associée à un contexte par l'analyse syntaxique dans laquelle il y a aussi une expansion des macros. L'inclusion d'un fichier avec include n'effectue qu'une analyse lexicale qui est effectuée par la procédure read-all. L'évaluation est effectuée après l'analyse syntaxique et l'expansion des macros. D'autres systèmes Scheme permettent le chargement des macros par load.

Dans un module, il y a du code qui est exécuté lors de l'expansion (les macros) et à l'évaluation. La procédure load donne accès aux procédures définies dans le module, mais pas aux macros, car elles sont expansées. Après un load, il ne reste que les procédures et variables globales qui résultent de l'expansion des macros. Pour avoir accès aux macros, il faut utiliser la forme spéciale include qui est expansée par le contenu du fichier. L'expression (include "foo.scm") est remplacée par le contenu du fichier foo.scm. L'exemple 2.5 montre un exemple de module simple n'utilisant que la procédure load.

Le standard R6RS[26], qui est une option possible pour concevoir le système de module, renforce le concept de module avec la forme syntaxique library qui a 4 parties: le nom, une sous-forme export, une sous-forme import et le corps du module. Le nom du module l'identifie de façon unique et il peut contenir une spécification de version. La version est spécifiée par une liste d'entiers positifs. Une liste vide () correspond à ne pas spécifier la version. Ensuite, il y a la liste des exportations qui est spécifiée par la sous-forme export. Chaque élément de cette liste est soit un identifiant ou une sous-forme rename qui renomme l'identifiant exporté. L'import donne la liste des dépendances du module. Chaque dépendance spécifie:

Fig. 2.5. Le fichier fact.scm est un exemple de module R4RS exposant la fonction mathématique fact. Le fichier main.scm est un programme principal qui utilise le module fact.scm.

- le nom du module importé et de façon optionnelle, une contrainte sur la version;
- le niveau d'import (temps d'expansion de macros ou évaluation);
- un sous-ensemble de l'export du module et le nom local utilisé au sein du module présent pour chaque exportation du module.

Le corps du module contient une séquence de définitions suivie par une séquence d'expressions. Une définition peut être locale ou exportée. Les expressions initialisent le module lors de l'exécution. Le R6RS ajoute aussi la forme import pour l'importation d'un module et enlève la procédure load. Contrairement au load, la forme import garantit le chargement unique d'un module. La syntaxe du import permet de manipuler les noms des symboles importés et exportés.

```
(library <library name>
  (export <export spec> ...)
  (import <import spec> ...)
  library body>)
```

Fig. 2.6. Structure globale d'un module R6RS

La forme import de R6RS permet l'importation d'un ensemble de modules. Chaque spécification d'import <import spec> peut être une simple importation ou une importation avec un niveau. Les différents niveaux d'importation sont: run, expand ou (meta <level>).

Le niveau méta donné par <level> est un entier exact. Un niveau d'importation 0 correspond à run et un niveau d'importation de 1 correspond à expand.

La syntaxe pour l'importation avec les niveaux méta est décrite dans la spécification R6RS [26]. Le import R6RS permet un grand contrôle lors de l'importation des modules au prix d'une sémantique plus complexe.

Les déclarations d'un module R6RS sont dans un espace distinct de l'espace global et des autres modules. Les déclarations d'un module ne peuvent pas être en conflit avec des déclarations globales ou d'autres modules. L'élément qui permet de distinguer deux modules est leurs identifications (nom avec version). Le nom du module correspond à l'espace de nom du module. C'est ce qui unit les déclarations au module et empêche les conflits de nom entre les modules.

Le standard R7RS[25] simplifie la syntaxe des modules R6RS[26]. L'importation d'un module fait abstraction du niveau d'importation. Les macros et les procédures sont importées de façon transparente. La procédure load est conservée. La forme spéciale pour définir un module est define-library. Il n'y a pas d'ordre spécifique dans les déclarations de la bibliothèque comme en R6RS. Un module R7RS commence par un nom suivi de plusieurs déclarations.

```
(define-library library name>
     declaration>*)
```

Fig. 2.7. Structure globale d'un module R7RS

Une déclaration dans un module est soit un import, un export, un include, un include-ci, un cond-expand ou un bloc begin.

- La déclaration import est équivalente au R6RS sans le concept de niveau d'importation.
- La déclaration export est idem au R6RS.
- Les déclarations include et include-ci permettent l'inclusion d'un fichier en tant qu'un bloc de code. La seconde forme non sensible à la casse des caractères.
- La déclaration cond-expand est une extension du SRFI-0 [9] dans le contexte d'une bibliothèque permettant l'inclusion conditionnelle de code.

La forme import en R7RS permet d'importer un ensemble d'identifiants qui sont exportés par un module. Chaque ensemble importé spécifie le nom des identifiants du module et parfois même associe un nom local aux identifiants. L'import peut prendre l'une des formes suivantes:

- tibrary-name>
- (only <import-set> <id1> ...)
- (except <import-set> <id1> ...)
- (prefix <import-set> <id>)
- (rename <import-set> (<id1> <id2>) ...)

Dans la première forme, tous les identifiants exportés par la bibliothèque 
library-name> sont importés. Les autres types de <import-set> modifient l'ensemble comme suit:

- only inclut seulement les identifiants spécifiés. C'est une erreur d'importer un identifiant non exporté par la bibliothèque.
- except permet d'exclure des identifiants de l'ensemble.
- rename renomme les identifiants importés.
- prefix ajoute un préfixe à l'ensemble des identifiants importés.

### 2.4. La syntaxe de Termite

Ce langage, conçu par Guillaume Germain en 2006, est l'implémentation du style de programmation par message d'Erlang dans Gambit Scheme. Les processus sont représentés par les threads de Scheme. La communication entre ces processus est effectuée par un système de boîte de message présent dans Gambit. Chaque thread possède une file d'attente de messages entrants.

Termite expose plusieurs procédures pour gérer les processus et la transmission de message entre chacun des nœuds.

- La procédure (spawn <thunk> #!key <name>) permet de créer des processus Termite. Le paramètre <thunk> est la procédure principale du thread. Le paramètre <name> est un paramètre associatif optionnel.
- La procédure (! <node> <msg>) envoie le message msg au nœud node.

- La procédure (?) permet de recevoir un message envoyé par un autre processus au nœud courant.
- La procédure (!? <node> <msg>) envoie un message au nœud node et attend la réponse.
- La macro (recv (<pattern> <expr1> ...) permet un filtrage par motif des messages reçus du nœud courant.

La figure 2.8 est un exemple d'application Termite. Cet exemple a un bogue volontaire, le serveur pong répond à un message ping par le message qnop au lieu de pong.

Dans cet exemple, il y a un scénario de mise à jour de code à la volée, c'est-à-dire sans interruption de service. Il y a deux nœuds, un serveur qui exécute le code de buggy-pong.scm et un client exécute le code ping.scm.

```
;; ping.scm (running on node1)
                                                           ;; buggy-pong.scm (running on node2)
(declare (block))
                                                           (declare (block))
(import (termite))
                                                           (import (termite))
(define pong-server
                                                           (define pong-server
 (remote-service 'pong-server node2))
                                                             (spawn
                                                               (lambda ()
                                                                 (let loop ()
(define new-server
 (letrec ((server-loop
                                                                   (recv
            (lambda ();; code that will be migrated
                                                                     ((from tag 'ping)
                                                                      (! from (list tag 'gnop))) ;; BUG!
                ((from tag 'clone)
                                                                     (('update k)
                 (call/cc
                                                                      (k #t)))
                   (lambda (k)
                                                                   (loop)))))
                     (! from (list tag k))))
                ((from tag 'ping)
                                                           (node-init node2)
                 (! from (list tag 'pong)))
                (('update k)
                                                           ;; publish the pong server
                 (k #t)))
                                                           (publish-service 'pong-server pong-server)
              (server-loop))))
 (spawn server-loop)))
(node-init node1)
(!? pong-server 'ping); => gnop
(! pong-server (list 'update (!? new-server 'clone)))
(!? pong-server 'ping); => pong
```

Fig. 2.8. Un serveur Ping-Pong en Termite Scheme

- (1) Le client envoie le message ping au serveur buggy-pong.
- (2) Le serveur répond par le message gnop, c'est un bogue.
- (3) Le client envoie le message clone au service local new-server contenant le code sans le bogue.

- (4) Le service local clone son état courant en capturant sa continuation par call/cc.
- (5) Le client envoie la l'état du service local au serveur buggy-pong par le message update.
- (6) Le serveur exécute la continuation, ce qui met à jour son code.
- (7) Le client envoie un autre message ping au serveur buggy-pong.
- (8) Le serveur répond par le message pong.

Dans ce scénario, la mise à jour de code est effectuée dans les étapes 4, 5 et 6. Cela permet de réparer le bogue qui est dans le serveur. Termite permet déjà la migration de code, mais sous certaines conditions.

Les nœuds doivent être interprétés, dans ce cas le code source des procédures est transmis. Ce qui permet d'exécuter du code arbitraire sur le nœud distant. Lorsque compilé, l'information transmis ne contient pas l'information du code source.

#### 2.5. Conclusion

Pour notre objectif de modularisation dans les systèmes distribués, les révisions de Scheme qui offrent les fonctionnalités requises sont R6RS et R7RS. Elles permettent toutes les deux la modularisation du code et la création de modules avec des noms uniques, ce qui est requis pour le bon fonctionnement du code mobile. Nous avons choisi l'approche avec define-library, puisque Gambit se veut compatible avec le R7RS. Cela a permis d'expérimenter avec le code mobile. En plus, cela facilite son adoption et sa portabilité entre les implémentations de Scheme qui sont de plus en plus compatibles avec R7RS. Les modules existent dans le langage de programmation Scheme. L'implémentation Gambit Scheme n'avait pas le support des modules.

## Chapitre 3

## Implémentation des modules

Ce chapitre traite de notre implémentation des modules dans Gambit qui se veut le plus portable entre les différentes implémentations de Scheme. Notre approche des modules se base sur la syntaxe de R7RS. Notre implémentation des modules utilise des formes déjà existantes et aussi de nouvelles formes qui ont été ajoutées au besoin. Ces nouvelles formes nous ont permis d'intégrer la syntaxe des modules R7RS avec les modules primitifs de Gambit. Il y a deux façons d'écrire des modules. Les modules primitifs sont utilisés pour implémenter des fonctionnalités système dans Gambit, par exemple, un module qui implémente une nouvelle syntaxe. La syntaxe des modules R7RS est utilisée lorsqu'un module se veut compatible avec d'autres implémentations du langage de programmation Scheme supportant R7RS.

Les formats des modules R7RS, construits avec define-library, contiennent plusieurs composantes.

- L'espace de nom du module qui regroupe toutes les fonctionnalités.
- Une liste des modules qui sont utilisés par le module courant.
- Une liste des symboles exportés par le module.

Il est possible de modifier les identifiants d'un module lors de l'importation et de l'exportation. L'importation multiple d'un module doit correspondre à un seul chargement. Pour exprimer les relations entre les modules certaines formes spéciales ont été ajoutées dans Gambit. Si les concepteurs de bibliothèques respectent la syntaxe R7RS, alors il est possible de l'importer dans Gambit. C'est indépendant du système Scheme pour lequel les bibliothèques ont été écrites.

#### 3.1. La notation des fichiers dans Gambit

Gambit utilise une notation qui est compatible avec l'environnement du système hôte. Il permet de référer au répertoire maison de l'utilisateur et aux répertoires d'installation.

Un chemin est une chaine de caractère qui dénote une ressource. Le séparateur des composantes d'un chemin dépend du système d'exploitation, Linux et macOS utilise '/' alors que MSDOS et Microsoft Windows utilise '\'.

La notation qui permet de référer au répertoire maison de l'utilisateur courant est par la notation '~' qui n'est pas suivit d'un '~'. Le nom qui suit '~' est le nom de l'utilisateur. Par exemple, ~USER représente le répertoire de l'utilisateur USER.

Un répertoire d'installation commence par les caractères '~~'. S'il n'y a rien qui suit ces caractères alors c'est le répertoire d'installation central. Sinon ce qui suit le '~~' est le nom du répertoire d'installation. Par exemple, '~~lib' est le chemin vers le répertoire d'installation 'lib' des bibliothèques système de Gambit. Il est a noté que Gambit permet de redéfinir l'emplacement des répertoires d'installation par l'utilisation de l'option d'exécution '-:~~NAME=DIRECTORY'.

### 3.2. La forme ##namespace

Un identifiant est un symbole, utilisé dans le code, qui n'est pas sous un quote. Par exemple pair? est l'identifiant de la procédure qui teste que le type de donnée est une paire. Il est généralement lié à une valeur ou une macro. Un symbole est un type de donnée primitif de Scheme.

Les espaces de nom sont gérés avec une forme spéciale propre à Gambit. Cette forme se nomme ##namespace et permet de lier des identifiants à d'autres identifiants dans le code. Cela affecte l'ensemble des identifiants spécifiés dans la forme ##namespace, l'ensemble vide correspond à tous les identifiants. Cette forme s'applique uniquement aux identifiants de variable et de macro. Elle ne s'applique pas aux valeurs. Cette forme primitive est présente dans Gambit depuis longtemps. Un espace de nom se compose de n'importe quelle séquence de caractère terminé par un #. Il y a seulement l'espace de nom vide qui est une exception à cette règle et c'est l'espace de nom par défaut. Les associations de symboles données par la forme ##namespace respectent la portée lexicale. Il y a trois types d'opérations avec les espaces de nom.

Il y a les espaces de nom global qui s'applique à tous les symboles qui ne contiennent pas de #.

```
(##namespace ("<ns>"))
;; <symbol-name> => <ns><symbol-name>
```

Fig. 3.1. Namespace Global

Il est possible de spécifier la liste des symboles qui sont affectés par la déclaration d'espace de nom. À partir de la syntaxe de la figure 3.1, il suffit d'ajouter les symboles après le nom de l'espace de nom.

```
(##namespace ("<ns>" A B ...))
;; A => <ns>A
;; B => <ns>B
;; ...
```

Fig. 3.2. Namespace Set

```
(##namespace ("<ns>" (<old> <new>) ...))
;; <old> => <ns><new>
;; ...
```

Fig. 3.3. Namespace Rename

Cette forme est utilisée pour créer un espace distinct pour chaque module. Cela permet d'éviter les conflits de nom entre les identifiants des modules. Chaque module commence par déclarer son espace de nom suivi des définitions des procédures du module. Les différentes formes d'espace de noms sont données par les figures 3.1, 3.2 et 3.3.

```
;; hello.scm
(##namespace ("hello#" hi))
(define (hi)
  (display "Hello, world!\n"))
(hi)
```

Fig. 3.4. Module Hello

L'exemple 3.4 est un exemple d'utilisation de la forme ##namespace pour créer un espace pour le module hello. La procédure hi est dans l'espace de nom hello#.

#### 3.3. La forme ##demand-module et ##supply-module

Le mécanisme de chargement des modules est géré par la forme spéciale ##demand-module. Cette forme indique au système de charger un module s'il n'est pas déjà chargé. Cette forme gère le chargement multiple d'un module. Elle est utilisée pour importer la liste des modules requis par le module courant. Le fonctionnement de cette forme est similaire à la procédure load avec quelques différences. La forme spécial ##demand-module génère une expression vide. L'effet de cette forme agit après la phase d'expansion des macros. Le paramètre passé à ##demand-module doit être un symbole qui correspond au nom du module. La procédure load requiert le chemin complet vers le fichier à charger.

Il est à noter que l'ordre dans lequel les ##demand-module apparaissent correspond à l'ordre dont les modules sont visités. Cette forme est permise partout où une définition de macro est permise.

Nous avons ajouté un forme spéciale conjointe au ##demand-module pour indique le nom symbolique des modules des modules exportés. Cette forme spéciale est ##supply-module, elle accepte comme paramètre le nom du module exporté par l'entité courant. La syntaxe de ces deux formes dans la figure 3.5.

```
(##demand-module <module-ref>)
(##supply-module <module-ref>)
```

Fig. 3.5. Syntaxe des formes demand-module et supply-module

#### 3.3.1. Les méta informations

Il est utile d'attacher à un module des informations qui sont accessibles lors de l'expansion et même la compilation. Ces informations sont spécifiées par la forme ##meta-info. Cette forme accepte au moins un paramètre qui correspond au nom de la méta information, le reste des paramètres est la valeur associée à la méta donnée.

```
(##meta-info <name> <value>)
(##meta-info <name> <value> ...)
```

Les méta informations sont utilisées pour donner des paramètres de compilation du module. Les différentes méta informations sont cc-options, ld-options, ld-options-prelude, pkg-config et pkg-config-path. Ces méta informations ne sont utiles que pour les modules compilés.

- Les cc-options sont ajoutés aux options de la commande qui invoque le compilateur C.
- Les méta informations ld-options et ld-options-prelude composent les paramètres de la commande qui invoque l'éditeur de lien. Les paramètres dans ld-options-prelude précèdent ceux qui sont dans ld-options.
- pkg-config contient le nom des bibliothèques C à être liées au module Scheme. Les options nécessaires pour le compilateur C sont déterminées automatiquement par l'utilitaire pkg-config.
- pkg-config-path ajoute des répertoires à la variable d'environnement PKG\_CONFIG\_PATH qui est utilisée par l'utilitaire pkg-config.

## 3.4. Implémentation des modules primitifs

Un module primitif est généralement constitué d'un fichier d'entête avec la déclaration de l'espace de nom et les définitions de macros et un fichier contenant les procédures. Dans Gambit les fichiers d'entête sont marqués par un # juste avant l'extension, tel que angle2/angle2#.scm.

- <name>#.scm est la structure du nom fichier d'entête. Ce fichier contient des déclarations d'espace de nom et des définitions de macros.
- <name>.scm est la structure du nom du fichier qui contient les procédures du module.

Le nom des fichiers doit correspondre à la dernière partie du nom de module. Par exemple, le module primitif angle2 doit inclure les fichiers angle2/angle2.scm et généra-lement angle2/angle2#.scm.

```
;; angle2/angle2#.scm
(##namespace ("angle2#" deg->rad rad->deg))

;; angle2/angle2.scm
(include "angle2#.scm")
(##namespace ("angle2#" factor))
(##supply-module angle2)
(define factor (/ (atan 1) 45))
(define (deg->rad x) (* x factor))
(define (rad->deg x) (/ x factor))
```

Fig. 3.6. Écriture d'un module qui implémente des fonctions de conversions entre les angles en degrés et en radian. Ce module est séparé en 2 fichiers. Le fichier angle2/angle2#.scm contient les exportations et angle2/angle2.scm contient l'implémentation des fonctions.

Dans l'exemple de la figure 3.6, il y a dans angle2/angle2.scm l'inclusion du fichier d'entête angle2/angle2#.scm qui ajoute une déclaration redondante de l'espace de nom dans ce cas. La déclaration (##namespace ("angle2#")) implique l'espace de nom ajouté par l'inclusion du fichier d'entête. Il est possible que l'espace de nom déclaré dans angle2/angle2#.scm soit différent de celui utilisé dans angle2/angle2.scm.

La forme ##namespace dans l'exemple 3.6 s'applique aux identifiants suivants:

```
factor --> angle2#factor
deg->rad --> angle2#deg->rad
rad->deg --> angle2#rad->deg
```

#### 3.4.1. La forme ##import

L'importation des modules est effectuée par la forme ##import qui effectue deux actions, l'inclusion du fichier <name>#.scm et un chargement des définitions. La forme ##import,

comme ##demand-module s'occupe de trouver l'emplacement du fichier d'entête à partir du nom du module. Elle génère le ##include du fichier d'entête s'il existe et un ##demand-module du module. L'importation (##import angle2) est équivalente à:

```
(##include "/un/chemin/angle2/angle2#.scm")
(##demand-module angle2)
```

Fig. 3.7. Expansion de (##import angle2)

### 3.5. Implémentation des modules R7RS

Pour que le système de module soit compatible avec d'autres implémentations de Scheme, les modules de haut niveau sont définis dans le standard R7RS Small [25]. Les modules sont définis par la forme define-library dont la syntaxe est donnée par la figure 2.7. Les formes define-library et import sont expansées dans les formes spéciales utilisées par les modules primitifs. L'élément qui distingue un module primitif et un module R7RS est donc l'utilisation de la forme define-library.

#### 3.5.1. Expansion du import

L'expansion de la forme import dépend du type de module qui est importé. L'importation d'un module primitif est différente de l'importation d'un module R7RS. Gambit permet l'importation d'un module primitif en utilisant la même forme que pour les modules R7RS. Les capacités du import dépendent de sa provenance, s'il est dans un define-library ou dans un programme principal. Dans le cas d'un define-library le import supporte l'importation relative, qui est une extension de Gambit.

#### 3.5.1.1. Importation d'un module primitif

L'importation d'un module primitif limite la syntaxe du import. Il n'est pas possible d'utiliser les extensions only, except et rename sur un module primitif. Pour utiliser ces extensions, il faut les métadonnées que les modules R7RS offrent. La structure modules primitifs ne contient pas de déclaration qui indique les identifiants uniformes. Pour avoir l'ensemble des identifiants qu'un module primitif il faudrait analyser l'ensemble des fichiers

du module primitif pour y extraire les identifiants qui sont exportés. Nous avons choisi la simplicité.

Le import R7RS se rabat sur le ##import des modules primitifs qui ne supporte pas les extensions R7RS. C'est une extension que nous avons ajouté dans notre implémentation des modules R7RS pour permet l'utilisation des modules primitifs dans un contexte R7RS.

Les modules R7RS ont tous la déclaration export qui donne l'ensemble des identifiants qui sont exportés. Les modules primitifs sont plus proches de R5RS avec un mécanisme de chargement sophistiqué. Le import requiert la méta information fournit par la déclaration export dans le define-library.

```
Les modules princifis font import (nerm RERS) et R7RS.

(##import termite)
```

Fig. 3.8. Expansion du import d'un module primitif

#### 3.5.1.2. Importation d'un module R7RS

L'importation d'un module R7RS est expansée en au plus trois parties.

- Un ##demand-module qui s'occupe de charger l'implémentation des procédures du module.
- Une déclaration d'espace de nom qui donne accès aux identifiants que le module exporte.
- L'implémentation des macros qui sont exportées par le module.

L'instruction de chargement du module est générée dans tous les cas qu'un module définit des procédures. Un module qui ne définit que des macros ne nécessite pas d'être chargé durant l'exécution seulement dans le contexte d'expansion des macros. L'importation d'un module R7RS qui ne contient qu'une déclaration export ne nécessite pas d'être chargé durant l'exécution. Ce type de module est utilisé pour exporter les fonctionnalités déjà implémentées dans Gambit dans un contexte R7RS.

La forme utilisée pour rendre disponible l'ensemble des identifiants importés est ##namespace. L'ensemble des identifiants importés dépend de la forme du import. Par défaut, tous les identifiants exportés par le module sont importés. Les opérateurs only et except affectent le nombre d'identifiants importés. Les opérateurs prefix et rename

affectent le nom des identifiants. Dans l'exemple 3.9, l'importation inclut l'ensemble des identifiants exportés par le module. L'ensemble des formes ##namespace générées par un import est donné par la figure 3.10.

```
;; expansion of (import (github.com/gambit/hello))
(##demand-module github.com/gambit/hello)
(##namespace ("github.com/gambit/hello#" hi salut))
;; macros
```

Fig. 3.9. L'exemple de l'expansion du import du module R7RS github.com/gambit/hello qui exporte les procédures hi et salut.

```
;; (import (only (github.com/gambit/hello) hi))
(##namespace ("github.com/gambit/hello#" hi))

;; (import (except (github.com/gambit/hello) hi))
(##namespace ("github.com/gambit/hello#" salut))

;; (import (prefix (github.com/gambit/hello) m-))
(##demand-module github.com/gambit/hello)
(##namespace ("github.com/gambit/hello#" (m-hi hi) (m-salut salut)))

;; (import (rename (github.com/gambit/hello) (hi howdy)))
(##namespace ("github.com/gambit/hello#" (howdy hi) salut))
```

Fig. 3.10. Différents ##namespace générés par l'expansion du import d'un module R7RS.

,

#### 3.5.2. Expansion du define-library

La forme define-library est expansée dans les formes qui composent un module primitif. Chacune des déclarations de la bibliothèque est utilisée dans l'expansion du define-library. La déclaration d'exportation est valide si tous les identifiants exportés sont distincts. Une déclaration export qui exporte un identifiant plusieurs fois cause une

erreur de syntaxe. Les informations sur les identifiants exportés ne sont pas utilisés lors de l'expansion du define-library, mais lors de l'importation de cette bibliothèque. Les déclarations import sont expansées de la même façon que dans des programmes principaux.

```
(define-library (hello)
  (import (scheme base) (scheme write))
  (export hi salut)
  (begin
     (define (exclaim msg1 msg2)
          (display msg1)
          (display msg2)
          (display "!\n"))
     (define (hi name) (exclaim "hello " name))
     (define (salut name) (exclaim "bonjour " name))
    ;; it is best for a library to not have side-effects...
#;(salut "le monde")))
```

Fig. 3.11. Le code source du module github.com/gambit/hello avant l'expansion.

```
;; expansion of (define-library (hello) ...)
(##declare (block))
(##supply-module github.com/gambit/hello)
(##namespace ("github.com/gambit/hello#"))
(##namespace ("" define ...))
(##namespace ("" write-shared write display write-simple))
(define (exclaim msg1 msg2)
        (display msg1) (display msg2) (display "!\n"))
(define (hi name) (exclaim "hello " name))
(define (salut name) (exclaim "bonjour " name))
(##namespace (""))
```

Fig. 3.12. Expansion de la forme define-library du module github.com/gambit/hello.

#### 3.5.2.1. Extensions de Gambit

Gambit offre des extensions au define-library et au import. L'importation dans le contexte d'une bibliothèque peut être relative au module courant. Plusieurs déclarations supplémentaires ont été ajoutées dans la forme define-library.

- namespace
- cc-options
- ld-options et ld-options-prelude
- pkg-config et pkg-config-path

La figure 3.13 est un exemple d'importation relative. L'importation relative part du module-ref du module courant. Un import de (.. C) à partir du module (A B) correspond à l'importation de (A C). Cela permet au sous-module de tests unitaires de référer au module principal en préservant le module-ref avec la version.

```
(define-library (A B)
  (import (.. C)) ;; => (import (A C))
  (import (..))) ;; => (import (A))
```

Fig. 3.13. Exemple d'importation relative du module

La déclaration namespace permet de forcer l'espace de nom d'un module. L'utilisation primaire de cette déclaration est l'implémentation de modules qui exporte les fonctionnalités déjà implémentées dans Gambit.

```
(define-library (scheme case-lambda)
  (namespace "")
  (export
  case-lambda
))
```

Fig. 3.14. Implémentation de la bibliothèque système (scheme case-lambda).

Les déclarations cc-options, ld-options, ld-options-prelude, pkg-config et pkg-config-path permet d'ajouter des éléments dans les méta informations respectifs.

#### 3.6. Conclusion

Nous avons ajouté la notion de module dans Gambit pour résoudre le manque de modularité dans le langage Termite. Les concepts concrets de module sont absents de Gambit. Les formes qui ont été ajoutées sont: ##demand-module, ##supply-module, ##import, import et define-library. Notre implémentation des modules utilise une forme compatible avec les autres implémentations de Scheme R7RS. En plus, les extensions que nous avons ajoutées offrent une interface avec les modules système de Gambit. L'implémentation actuelle des modules est suffisante pour permettre la diffusion de code, car elle offre des identifiants uniques pour les modules.

Notre approche supporte la création de modules qui dépendent de bibliothèques du système d'exploitation. Cela est réalisé par les extensions de la forme define-library et par la FFI de Gambit. Le système de module permet de regrouper de façon logique les fonctionnalités dans un module.

# Chapitre 4

## Modèle de chargement

Ce chapitre traite des mécanismes de chargement que nous avons implémenté pour le système de module. Dans notre implémentation, les modules sont référés par un nom symbolique plutôt que leur emplacement sur le système de fichier. Elle garantit l'ordre dans lequel ils sont chargés et aussi le chargement unique de chaque module. Pour permettre la diffusion des modules, nous avons ajouté un mécanisme d'installation automatique et de chargement des modules à la volée.

Un système est composé d'un ensemble de modules qui interagissent entre eux. L'interaction entre les modules est dans un contexte statique ou dynamique. Dans le contexte statique, les modules sont incorporés au sein de l'application, ils n'ont pas besoin d'être chargés. Dans le contexte dynamique, les modules sont externes à l'application et requièrent un chargement dynamique. Le chargement dynamique de modules est une partie importante dans un système de modules, il permet l'utilisation de modules externes.

La diffusion des modules requiert que le chargement de modules qui ne sont pas encore installés soit effectué durant l'exécution.

### 4.1. Chargement des bibliothèques

Le chargement d'une bibliothèque Scheme (ou module) dans Gambit est séparé en plusieurs niveaux. Il y a la phase de recherche du module et de ses dépendances qui valide la présence, sur le système de fichier ou en mémoire, de tous les modules nécessaires. Ensuite, le module et ses dépendances sont chargés dans un ordre qui respecte les relations de dépendance. Un module est soit sur le système de fichier ou déjà en mémoire. L'emplacement des bibliothèques sur le système de fichier est lié par défaut aux chemins spécifiés par le ##module-search-order qui a comme défaut ~~lib et ~~userlib.

La procédure exacte de chargement des bibliothèques par import n'est pas spécifiée par le standard R7RS. Le standard spécifie seulement une syntaxe de base et le comportement principal qui est requis. L'importation d'une bibliothèque doit charger la bibliothèque et rendre ses fonctionnalités disponibles dans le contexte où l'importation a eu lieu (qui peut soit venir d'un programme principal ou d'une bibliothèque).

Le chargement d'une bibliothèque peut-être effectuée à l'exécution par l'utilisation de eval (par load) pour les fichiers source et load-object-file pour les bibliothèques compilées. Cette recherche peut aussi avoir lieu durant l'édition des liens en utilisant les méta-infos contenues dans les fichiers .c qui sont chacun compilés par le compilateur C en .o et lié par l'éditeur de lien.

### 4.2. Modèle statique

Le modèle de bibliothèque statique consiste à intégrer la bibliothèque dans le fichier exécutable de l'application finale. La bibliothèque n'a donc pas besoin d'être chargée durant l'exécution. L'avantage du modèle statique est sur le plan du déploiement. Puisque toutes les dépendances sont dans l'application finale, il suffit de distribuer celui-ci. Le compilateur Gambit supporte un modèle statique pour des programmes simples. Compiler une application liée statiquement est possible de façon manuelle. Pour lier statiquement deux fichiers Scheme simples, il suffit d'invoquer le gsc comme suit:

Un des problèmes du modèle statique est le coût lié à la maintenance. Les programmes qui utilisent des bibliothèques statiques ne permettent pas une construction modulaire. La mise à niveau d'une des bibliothèques statiques nécessite la recompilation du programme au complet. En plus, cela n'est pas adapté pour des applications évolutives qui peuvent être étendues par l'utilisateur. Une solution qui a été adoptée est le modèle dynamique, présenté dans la prochaine section. Cela offre une plus grande flexibilité dans le déploiement des programmes.

### 4.3. Modèle dynamique

Dans le modèle dynamique, chaque module externe est séparé durant l'exécution. L'application contient les informations pour accéder aux fonctionnalités des modules durant l'exécution. Le déploiement d'une application nécessite la distribution de toutes les dépendances directes et indirectes. Les bibliothèques partagées offrent plusieurs avantages par rapport aux bibliothèques statiques.

Dans ce modèle les bibliothèques sont liées au programme durant l'exécution. Cela nécessite que les bibliothèques soient organisées sur le système de fichier d'une façon distinguable. Chaque module doit posséder un nom unique qui permet d'y référer. Ce nom unique va être utilisé lors de la collection des dépendances.

La recherche des bibliothèques est effectuée dans un ordre spécifique indépendant de la spécification. L'algorithme de recherche des bibliothèques prend en paramètre le nom de la bibliothèque et retourne le chemin absolu correspondant à son emplacement dans l'arborescence du système de fichier. Les bibliothèques sont situées dans différents répertoires: le répertoire des bibliothèques système (~~lib) et le répertoire des bibliothèques utilisateur (~~userlib) ou des répertoires explicitement ajoutés au «module search order».

Chaque module possède trois niveaux d'initialisation dans le système numérotés de 0 à 2. Le niveau 0 indique que le module est collecté en mémoire, mais non initialisé. Le niveau 1 indique que l'initialisation de bas-niveau a été complétée et que le descripteur Scheme du module a été récupéré. Le niveau 2 marque les modules chargés dont toutes les définitions et expressions au niveau principales («top level») ont été evaluées et donc le module est prêt à être utilisé.

Dans l'exemple à la figure 4.2, l'exécution du module principal **main.scm** déclenche la collection des modules X et Y, qui récursivement déclenche la collection de W et Z. L'algorithme de collection des modules gère les modules qui apparaissent plusieurs fois au sein du graphe et les cycles. Après la collection de tous ces modules, le descripteur de module est récupéré par un appel aux primitives du système d'exploitation si compilé.

```
> (define mods (##collect-modules '(_zlib)))
> mods
(#(_digest 0 #(#(_digest) #() () 1 #<procedure #2> ...))
  #(_zlib 0 #(#(_zlib) #(_digest) () 1 #<procedure #4> ...)))
> (##init-modules mods)
#t
> ##registered-modules
(#(_digest 2 #(#(_digest) #() () 1 #<procedure #2 _digest#> ...))
  #(_zlib 2 #(#(_zlib) #(_digest) () 1 #<procedure #4 _zlib#> ...))
  ...)
```

Fig. 4.1. Un exemple qui montre la collection des modules à partir du module \_zlib suivit de l'initialisation des modules collectés. La collection des modules est effectuée par la procédure ##collect-modules. L'ensemble des modules retournés sont initialisés par la procédure ##init-modules. Les enregistrements des modules \_zlib et \_digest ont été ajoutés à la liste des modules enregistrés (variable ##registered-modules).

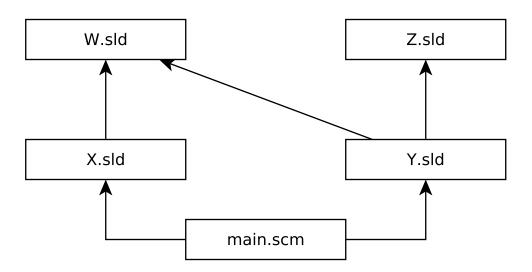


Fig. 4.2. Un exemple d'un système fictif composé de différents modules. Le module principal se nomme main.scm avec l'extension .scm et les bibliothèques ont l'extension .sld

#### 4.3.1. Module compilé dans Gambit

Les modules dans Gambit peuvent être compilés pour plus de performance en bibliothèque dynamique. Les programmes principaux peuvent être compilés en exécutable. Gambit permet l'utilisation de bibliothèques statiques et dynamiques.

Fig. 4.3. Un module qui implémente la fonction mathématique fib au niveau principal («top level»).

La construction d'une bibliothèque dynamique à partir du fichier fib.scm de la figure 4.3 s'effectue par le compilateur de Gambit qui se nomme gsc depuis longtemps. Cela produit un fichier avec l'extension .oN où le N correspond à la version générée de la bibliothèque qui commence à 1. Gambit support déjà une gestion des versions des modules compilés avant l'intégration du système de module.

## 4.4. Module hébergé

Un module qui est hébergé est un module dont le code source est stocké sur un serveur de versionnement de source accessible sur le réseau au nœud d'un nom de domaine comme github.com. La syntaxe des noms de domaine est inspirée du RFC-2396 [3]. La différence avec la spécification du *hostname* dans le RFC-2396 est que le *hostname* ne peut pas se terminer par un point et doit contenir au moins un domainlabel. C'est pour permettre de distinguer un module local et un module hébergé.

```
hostname = (domainlabel ".") + toplabel
domainlabel = alphanum | alphanum (alphanum | "-") * alphanum
toplabel = alpha | alpha (alphanum | "-") * alphanum
alphanum = alpha | digit
alpha = [a-zA-Z]
digit = [0-9]
```

**Fig. 4.4.** Grammaire EBNF représentant un hostname selon un sous-ensemble du RFC-2396.

#### 4.4.1. Installation automatique

Gambit permet l'installation automatique des modules. Pour contrôler les provenances des modules qui sont installés automatiquement, nous avons ajouté une liste des emplacements de confiance à l'environnement d'exécution qui indique quels modules peuvent être installés inconditionnellement. Nous avons nommé cette liste whitelist, elle valide les <module-ref>. La validation consiste à trouver un élément dans la whitelist qui correspond à un préfixe du <module-ref>. Chaque processus Gambit possède une whitelist différente, cela implique que chaque nœud Termite peut avoir une whitelist distinct.

Un élément est considéré un préfixe, si chacune des composantes de l'élément est incluse dans le *<module-ref>* dans le même ordre. L'élément github.com/gambit est un préfixe de github.com/gambit/hello, car les parties github.com et gambit font partie du *<module-ref>*. Le module github.com/gambitXYZ/hello ne contient pas le préfixe github.com/gambit, car gambit est différent de gambitXYZ.

Par défaut l'emplacement github.com/gambit est inclus dans la whitelist, puisque cela correspond à la emplacement qui de des sources de Gambit. Cela implique que tous les modules sous github.com/gambit peuvent être installés automatiquement. Par exemple, le module github.com/gambit/hello peut être installé inconditionnellement. La whitelist peut être modifiée par les variables d'environnement et par les arguments de ligne de commande.

En plus de la *whitelist* nous avons aussi ajouté un mode d'installation. qui indique si l'installation demande une confirmation à l'usager pour l'installation d'un module qui n'est pas dans la *whitelist*. Il y a trois modes d'installation.

```
$ gsi -e '(import (github.com/feeley/pyffi))'
*** ERROR IN (stdin)@1.9 -- Cannot find library (github.com/feele
$ gsi -:whitelist=github.com/feeley -e '(import (github.com/feele
$ gsi -:whitelist= -e '(import (github.com/gambit/hello))'
*** ERROR IN (stdin)@1.9 -- Cannot find library (github.com/gambi
```

Fig. 4.5. Exemples de manipulation de la *whitelist* par les arguments de la ligne de commande. Le premier exemple montre le rejet de l'installation, car le module n'est pas dans la *whitelist*. Le second exemple permet les modules sous github.com/feeley d'être installé automatiquement. Le dernier exemple montre comment désactiver l'installation automatique en vidant la whitelist.

- never: il y a seulement les modules qui sont dans la *whitelist* qui peuvent être installés.
- repl (Read Eval Print Loop): les modules qui ne sont pas dans la whitelist peuvent être installés avec la confirmation textuelle de l'usager s'il y a une repl disponible. C'est le mode par défaut.
- ask-always: les modules qui ne sont pas dans la *whitelist* peuvent être installés avec la confirmation textuelle de l'usager.

Le mode d'installation est spécifié par le runtime option nommée ask-install.

#### 4.5. Conclusion

Ce chapitre a traité des méthodes de chargement de module et des mécanismes d'installation automatique qui sont requis dans la diffusion des modules. Notre implémentation du chargement des modules garantit le chargement unique des modules dans un ordre qui respecte les dépendances. Ceci est demandé dans l'implémentation des modules Scheme R7RS.

Notre approche nous permet l'installation automatique de modules qui sont inclus dans la *whitelist* lorsque demandé. Cela offre une forme simple de contrôle de sécurité sur les modules qui peuvent s'installer automatiquement sur un nœud du système distribué. Cela

```
$ gsi -:ask-install=always
Gambit v4.9.3

> (import (github.com/frederichamel/semver))
Hosted module github.com/frederichamel/semver is required but is not installed.
Download and install (y/n)? n

*** ERROR IN (stdin)@1.9 -- Cannot find library (github.com/frederichamel/semver)
>
```

**Fig. 4.6.** L'exemple montre le résultat d'une réponse négative lors de l'installation du module qui n'est pas dans la *whitelist*. Il ne se fait pas installer.

offre la diffusion des modules entre les nœuds d'un tel système pour permettre des appels RPC sur un nœud ne connaissant pas le code demandé.

# Chapitre 5

### Gestion des modules

Ce chapitre décrit l'organisation des modules sur le système de fichier que nous avons choisi pour permettre plusieurs versions d'un module. Notre approche est d'associer à chaque version d'un module un répertoire différent. Cela permet de stocker les différentes versions d'un module dans le système de fichier. Nous avons comparé les différentes façons d'organiser les modules dans plusieurs langages comme Python, JavaScript, Go, OCaml. Il est important que l'installation d'un module n'altère pas le bon fonctionnement des autres modules. Le modèle de gestion des modules choisi garantit que les dépendances d'un module sont fixes.

#### 5.1. Sommaire

La gestion des modules inclut généralement l'installation, la mise à jour et la désinstallation. L'organisation des modules est un élément important dans la gestion des modules. Les gestionnaires de modules sont présents dans beaucoup de langages tels que Python, Ruby, JavaScript, Common Lisp, Go, etc. Un gestionnaire de module est inclus dans le système Gambit Scheme pour organiser les modules.

Le gestionnaire de module de Gambit Scheme fournit les opérations d'installation, de désinstallation, de mise à jour, de compilation d'un module et l'exécution des tests unitaires du module. Les modules sont versionnés par Git. L'emplacement des modules est spécifié par une liste de répertoires qui inclut les modules système et les modules utilisateur. La gestion des modules est effectuée par le module \_pkg qui offre les procédures d'installation et de désinstallation.

### 5.2. Organisation des modules

Les modules sont organisés dans des répertoires donnés par le système Gambit. Ils contiennent l'ensemble des modules internes et actuellement installés sur le système. Il y a trois principaux répertoires spéciaux qui contiennent des modules.

- ~~userlib: c'est le répertoire qui contient les modules de l'utilisateur, par défaut .gambit\_userlib dans le répertoire maison de l'utilisateur.
- ~~lib: c'est le répertoire d'installation de Gambit qui contient les modules système. Les modules dans ce répertoire sont communs à tous les utilisateurs.
- ~~instlib: c'est le répertoire d'installation des modules. Par défaut, il correspond au répertoire ~~userlib.

Un module local ou hébergé est identifié de façon unique par un module-ref. Un module-ref est séparé en trois parties: le hostname, le path et l'étiquette qui donne la version. La différence entre une référence à un module local et hébergé est la première partie. Dans le cas hébergé, le champ hostname contient l'information du nom de domaine qui, dans le cas local, est vide. Le <tag> spécifie la version du module avec une référence à un commit du système de révision Git. Un <tag> vide réfère à la version de développement du module (à éviter pour le déploiement final). La syntaxe du nom de domaine est donnée par la grammaire à la figure 4.4. La grammaire formelle à la figure 5.1 décrit la syntaxe du <module-ref> dans le cas hébergé et local.

```
<module-ref> := <local> | <hosted>
<local-package> := <id>
<hosted-package> := <hostname>/<id>/<id>
<local-module> := <local-package>(/<id>)*@<tag>
<hosted-module> := <hosted-package>(/<id>)*(@<tag>)?
```

Fig. 5.1. Grammaire formelle d'un module-ref

La règle <id> est liée à un élément de l'URL vers le dépôt de code. Par exemple, le module-ref github.com/gambit/hello réfère au module hello sur le serveur de révision github.com dans l'espace gambit, les <id> sont respectivement gambit et hello. Le champ host est dans ce cas github.com/gambit qui correspond au nom de domaine avec le nom de

l'espace sur le serveur. Les deux <id> dans la syntaxe d'un module hébergé correspond au nom utilisateur ou de l'organisation (par exemple gambit) et au nom du dépôt sur le serveur de version.

#### 5.2.1. Installation des packages et des modules

Les modules sont versionnés par un système de gestion de version pour permettre de différencier et conserver chaque version du module. Un package est un regroupement de modules. L'installation d'un package est faite à partir d'un serveur de révision ou un répertoire local qui est versionné par un système de gestion de versions (git, hg, svn). La syntaxe d'un package local est donné par la règle <local-package> de la figure 5.1 et la syntaxe d'un package hébergé est donné par la règle <hosted-module>. Chaque package est associé à un répertoire unique.

Les packages déployés sont généralement hébergés sur des serveurs de version tels que github, gitlab, bitbucket, etc. Une version d'un module est installée à partir d'un package dans un répertoire distinct. Il est donc possible d'avoir plusieurs versions d'un module installées sur le système de fichier.

L'installation d'un *package* est faite par le module \_vcs qui offre une interface uniforme aux outils de gestion de versions tels que git, hg et svn. Le processus d'installation est séparé en plusieurs étapes.

- (1) Le package est téléchargé dans un répertoire temporaire.
- (2) Le répertoire temporaire est renommé au répertoire prévu de façon atomique.

Cette procédure d'installation garantit qu'un seul processus d'installation peut installer ce package.

Les modules sont installés en même temps que le *package* qui les contient. La version des modules correspond à la version du *package*. Chacun des modules est contenu dans un sous répertoire du *package*.

Tout d'abord, la branche principale du dépôt du package est clonée dans un répertoire unique dans le préfixe d'installation qui est par défaut ~~userlib. L'installation d'un module se fait par la copie de ses fichiers dans le package dans un dossier temporaire qui est renommé dans un dossier @<version> dans le répertoire du package. Le répertoire @ est utilisé comme version de développement qui change avec les mises à jour du package. Plusieurs versions

d'un module peuvent coexister dans un même préfixe d'installation, puisque chaque version est associée à un répertoire différent. La version d'un module spécifié par une étiquette au sein du système de gestion de version.

Il est possible d'installer un module par une procédure dans le langage. La procédure install du module interne \_pkg permet l'installation de module, elle accepte deux paramètres: le nom du module et de façon optionnelle le préfixe d'installation. Le module est installé par l'installation du package englobant. Elle retourne la valeur de vérité vraie (#t) si l'installation réussit, sinon elle retourne la valeur de vérité fausse (#f).

#### (install mod #!optional dir)

L'installation des package peut aussi s'effectuer par l'invocation de l'interprète Gambit avec l'option -install. Cette option requiert le nom du package. Le répertoire d'installation optionnel est spécifié par l'option -dir. Il est possible de spécifier un répertoire local où le package est situé. Un paramètre est reconnu comme un répertoire local, s'il termine soit par une barre oblique (/) ou par un point.

#### \$ gsi -install [-dir <path>] [local-dir] package

Le répertoire d'installation <path> est la racine utilisée pour installer les modules et est spécifié par l'option -dir. La racine par défaut est ~~userlib. Voici un exemple d'installation d'une version spécifique du module semver qui implémente la logique du semantic versioning[24] qui est une façon d'organiser les versions. Cette organisation est recommandée pour étiqueter les versions. La présente version de système de module ne requiert pas l'utilisation du semantic versioning. Les figures [5.2, 5.3,5.4] montrent les différentes façons d'installer d'un package en invoquant de l'interprète Gambit.

\$ gsi -install github.com/frederichamel/semver

**Fig. 5.2.** Exemple d'installation d'un *package* hébergé dans le préfixe d'installation par défaut.

\$ gsi -install -dir /tmp/exemple github.com/frederichamel/semver

Fig. 5.3. Exemple d'installation d'un package hébergé dans le préfixe d'installation /tmp/exemple

\$ gsi -install -dir /tmp/exemple /local/dir/ github.com/frederichamel/semver

Fig. 5.4. Exemple d'installation d'un package dans le préfixe d'installation /tmp/exemple à partir du répertoire local /local/dir/.

#### 5.3. Désinstallation

Il est possible de désinstaller une version d'un module spécifique où le package au complet. La désinstallation d'un module consiste à supprimer les fichiers de ce module. Le module \_pkg offre la procédure uninstall qui accepte deux arguments: le nom du module, et de façon optionnelle, le répertoire dans lequel les modules sont situés. Les valeurs retournées par cette procédure sont similaires à la procédure install.

La désinstallation peut être faite en passant l'option -uninstall à l'interprète Gambit. Cette option requiert le nom du module et le répertoire des modules à désinstaller.

Le répertoire <path> est l'emplacement des modules à désinstaller. Le format des arguments pour la désinstallation est le même que pour l'installation. Le répertoire par défaut est le répertoire ~~userlib.

La désinstallation du module semver qui est installé dans le répertoire /tmp/exemple est fait par la commande suivante:

\$ gsi -uninstall -dir /tmp/exemple github.com/frederichamel/semver

## 5.4. Mise à jour

Cette opération actualise le package courant. Cela donne accès aux nouvelles publications d'un module. Le répertoire @ est effacé et remplacé par le dernier état de la branche de développement. Pour installer une nouvelle version d'un module, il suffit de faire la mise à jour de la branche master et d'installer la nouvelle version. La mise à jour d'un module n'affecte pas les versions spécifiques, comme la version 1.0. Cette opération est utilisée pour synchroniser le dépôt local avec le dépôt web. Sans cette opération l'installation de versions plus récente échouerait quand ils ne sont pas dans la cache locale du dépôt. La mise à jour d'un module est l'équivalent d'un pull dans git.

Notre système de module permet l'installation d'une branche. L'opération de mise à jour sur cette branche n'est pas encore supportée. C'est un élément qui est à rafiner.

#### 5.5. Tests unitaires

Les tests unitaires exécutés sont dans un fichier conjoint au module. Gambit offre un module de test unitaire nommé \_test. Il contient plusieurs procédures et macros pour tester le bon fonctionnement d'un module. Les tests unitaires pour un module nommé A sont par convention dans le sous-module A/test.

```
$ gsi module/test
*** all tests passed out of a total of N tests
```

La commande affiche le résultat des tests unitaires contenus dans le sous-module test.

### 5.6. Compilation d'un module

La compilation d'un module est faite en passant le nom du module (<module-ref>) en paramètre. Le compilateur cherche le module dans les répertoires du ##module-search-order. Le module est installé au besoin et ensuite compilé dans un sous répertoire. Ce dossier associe la compilation de ce module à la version de Gambit et à la cible (C, JavaScript, ...). La compilation d'un module se fait par la commande suivante:

L'arborescence du répertoire du module après la compilation du module \_digest pour le backend C est:



Il est possible de forcer la compilation d'un module par la présence d'un fichier module-name.\_must-build\_. Cette fonctionnalité permet le chargement d'un module qui doit être compilé pour fonctionner.

### 5.7. Comparaison avec d'autres systèmes

L'organisation des modules sur le système de fichier dans Gambit diffère de celui de OCaml, Python et NodeJS et des autres implémentations de Scheme. Akku[29], un gestionnaire de module pour Scheme compatible avec plusieurs implémentations de Scheme comme Chez Scheme, Chibi Scheme et GNU Guile. Il gère les modules pour les projets. Une seule version de chaque module peut être installé dans un projet.

Ceux-ci ne permettent pas l'installation de plus d'une version d'un module directement. Le système de module qui est utilisé dans le langage de programmation Go est le plus similaire à celui dans Gambit.

Notre système offre l'identification unique des modules, ce qui permet d'installer plusieurs versions d'un module. Un système de module permet la coexistence de plusieurs versions du même module sur le système de fichier s'ils sont considérés comme des modules différents. L'installation d'une version différente d'un module ne remplace pas la version déjà installée. L'organisation des bibliothèques est importante pour permettre cette coexistence.

La caractéristique que le système de bibliothèque doit avoir pour permettre plusieurs versions d'une bibliothèque est une organisation qui permet de distinguer les différentes versions de la bibliothèque par un chemin unique. La plupart des systèmes de module ne distinguent pas les versions d'un même module et ne permettent l'installation que d'une seule version. Les systèmes de module permettent la gestion de différents préfixes dans lesquels les modules sont installés. Chaque préfixe peut contenir une version différente d'un même module. Pour avoir une nouvelle version d'un module, il faut créer un nouveau préfixe.

#### 5.7.1. Organisation de OCaml

Le système de gestion de bibliothèques d'OCaml se nomme OPAM. Ce système permet d'avoir plusieurs environnements distincts contenant chacun un ensemble de versions des bibliothèques. Chaque environnement permet l'installation d'une version spécifique de chaque bibliothèque et est étiqueté avec un nom choisi par l'utilisateur. Un changement d'environnement est effectué par une requête de l'utilisateur opam switch <envname>. Il utilise le projet mancoosi pour gérer les contraintes de version, les dépendances optionnelles et la gestion des conflits. L'environnement par défaut est lié aux dépôts standard d'OCaml.

	Multiple versions
OCaml	×
Python	×
NodeJS	Х
Java	Х
Go	✓
Akku	X
Racket	×
Chez Scheme	×
Gambit	✓

Fig. 5.5. Une table qui compare différents systèmes de module sur la capacité d'installer plusieurs versions d'un module. Le système Go permet plusieurs versions d'un module pour des versions incompatibles selon le sémantique de version. La version 1.0.0 coexiste avec la version 2.0.0. La version récente 1.2.0 remplace la vieille version 1.0.1.

### 5.7.2. Organisation de Python

L'organisation des bibliothèques Python ne permet de stocker qu'un (typiquement la dernière) version d'une bibliothèque. Les emplacements des bibliothèques sont modifiés par la variable d'environnement PYTHONPATH qui correspond dans Python à la variable path de la bibliothèque interne sys. Le système de bibliothèque de Python ne permet pas la coexistence de plusieurs versions de la même bibliothèque. Le package manager principal de Python est pip. L'installation d'une autre version d'une bibliothèque désinstalle ou masque la version déjà installée. Le système de module ne permet pas de référer à deux versions de la même bibliothèque.

Python a le concept équivalent à OCaml de virtualenv qui permet d'avoir plusieurs versions installées sur la même machine. Cela permet d'installer des bibliothèques dans un environnement isolé des autres. L'avantage est qu'il est possible d'avoir une compatibilité avec des logiciels qui utilisent des versions de bibliothèques antérieures. Un inconvénient est qu'il n'y a pas un partage des versions de bibliothèques communes entre les différents environnements, cela a comme effet d'avoir plus d'un exemplaire d'une version de la bibliothèque

```
>>> import sys
>>> print('\n'.join(sys.path))
/usr/lib/python37.zip
/usr/lib/python3.7
/usr/lib/python3.7/lib-dynload
/home/username/.local/lib/python3.7/site-packages
/usr/lib/python3.7/site-packages
```

**Fig. 5.6.** L'ensemble des répertoires qui est utilisé par Python version 3.7 pour organiser les bibliothèques sur un système de type Linux.

installée sur le système de fichier. Chaque virtualenv ne permet qu'une seule version de chaque bibliothèque d'être installé.

#### 5.7.3. Organisation de NodeJS

NodeJS est un interprète JavaScript qui a été conçu pour être exécuté du côté serveur dans un modèle client-serveur. Les bibliothèques sont installées au niveau du projet. Cela implique que plusieurs projets qui utilisent la même version de la bibliothèque vont référer au même exemplaire de la bibliothèque.

La structure d'une bibliothèque dans NodeJS est décrite par un fichier package.json qui contient plusieurs méta données comme le nom, la version, le nom des dépendances, la version des dépendances, la licence sous laquelle la bibliothèque est publiée et plusieurs autres méta données liées à la bibliothèque. Sous NodeJS, les bibliothèques sont gérées par projet plutôt que globalement cela a comme avantage que chaque projet fonctionne avec ses versions des bibliothèques.

#### 5.7.4. Organisation de Java

Les modules en Java sont nommés package. Le nom des modules utilise généralement l'inverse d'une URL comme espace de nom. Par exemple, les noms des modules liés aux services Google vont débuter par com.google. Cette convention a pour but d'unifier les noms de module. La version des modules n'est pas liée au nom du module dans le cas de Java. Il n'est pas possible de charger deux modules qui utilisent le même espace de nom, comme deux versions d'un même module.

Les projets Java utilise générallement Gradle ou Maven des système de *build* automatique. Ces système gère l'installation et la compilation des dépendances.

#### 5.7.5. Organisation de Go

L'organisation des bibliothèques dans Go [4] est plus dans un contexte environnement dont la racine est spécifiée par la variable d'environnement GOPATH avec un répertoire pour les exécutables compilés (bin), un répertoire contenant le code source des différents projets (src) et un répertoire pour les objets des modules installés (pkg). Chaque paire de systèmes d'exploitation et d'architecture a son propre répertoire dans pkg.

Le système Go permet l'installation de plusieurs versions d'un même module dans le même environnement en utilisant le service *gopkg.in*. Il y a deux syntaxes utilisées pour l'URL des modules Go avec *gopkg.in*. Il est possible de spécifier une version spécifique du module lors de l'importation.

```
gopkg.in/pkg.v3 -> github.com/go-pkg/pkg (branch/tag v3, v3.N, or v3.N.M)
gopkg.in/user/pkg.v3 -> github.com/user/pkg (branch/tag v3, v3.N, or v3.N.M)
```

**Fig. 5.7.** Exemple d'importation de la version v3 du module pkg en utilisant le service *gopkg.in*.

#### 5.8. Conclusion

Ce chapitre a traité de la gestion des modules. Les opérations du système de modules présentés dans ce chapitre sont l'installation, la désinstallation et la mise à jour. Notre approche de gestion des modules offre correctement la possibilité d'avoir plus d'une version d'un module. Cela empêche les bris de dépendances lors de l'installation de nouveaux modules. L'installation des modules peut-être déclenchés procéduralement ce qui est nécessaire pour diffuser les modules. Notre approche de gestion, qui utilise le nom du module et sa version, permet d'identifier de façon unique les modules et de les conserver dans le système de fichier. L'installation automatique des modules avec le chargement dynamique permet l'évolution d'une application sans qu'il soit redémarré. C'est une partie important de la diffusion des modules.

```
package main

import (
  hellov1 "gopkg.in/FredericHamel/go-hello.v1"
  hellov2 "gopkg.in/FredericHamel/go-hello.v2"
)

func main() {
  // use hello version 1
  hellov1.Hello("Bob")

  // use hello version 2
  hellov2.Salut("Alice")

  // hellov1.Salut("Eve")
}
```

Fig. 5.8. Un exemple qui montre l'importation de deux versions d'un même module en Go. Le module go-hello version 2 exporte la fonction Salut qui n'existe pas dans la version 1.

```
$GOPATH/
- bin
- ... binaries
- src
- github.com
- UserName1
- project1
- project2
- UserName2
- projectA
- projectB
- pkg
- linux_amd64
- pkglist
- objets
```

Fig. 5.9. Arborescence des fichiers dans le gopath.

# Chapitre 6

## Migration de code

Ce chapitre traite du mécanisme de diffusion de modules qui est utilisé dans la migration de code. Notre approche exploite la sérialisation des objets Scheme, le langage Termite et l'installation automatique des modules durant l'exécution.

La migration de code entre les nœuds d'un système distribué n'est possible que si chaque nœud utilise la même version de Gambit configuré avec les mêmes paramètres. Des versions différentes de Gambit vont compiler le code différemment, ce qui peut rendre la sérialisation/désérialisation possiblement incompatible. La compilation des modules doit utiliser les mêmes déclarations et optimisations Scheme. Le compilateur C, le système d'exploitation, la taille des mots mémoires n'ont pas d'importance.

## 6.1. Systèmes distribués

Les systèmes distribués sont constitués d'un ensemble de nœuds interconnectés de calculs. Les nœuds interagissent par l'envoi et la réception de message au sein d'un réseau de communication. Chaque nœud a un but spécifique. Le *Web* est un exemple notable qui permet d'avoir un aperçu. Il est composé de clients et de serveurs qui exécutent des applications clients et serveurs différentes.

L'implémentation d'un système distribué inclut le développement des applications installé sur les nœuds et la logique d'interaction entre les nœuds. Il est possible de voir l'ensemble des programmes sur les nœuds comme un programme global. Les problèmes discutés dans ce chapitre sont les suivants:

• RPC: Comment l'appel distant à une procédure (RPC) implémentée quand l'envoyeur et le receveur ne sont pas conçus ensemble?

- Mise à jour de code: Comment la mise à jour du programme d'un nœud est effectuée lors d'un bugfix ou lorsqu'une nouvelle version est disponible?
- Migration de tâche: Comment déplacer un service sur un nouveau nœud quand le système sous-jacent est sur un système d'exploitation différent, à une architecture différente, etc.?
- Opération continue: Comment éviter les interruptions dans les situations précédentes?

Le langage Termite Scheme [12] a été conçu pour simplifier l'implémentation de systèmes distribués et fournit certaines solutions aux problèmes de ces systèmes. Le langage Termite Scheme est fortement inspiré des concepts du langage de programmation d'Erlang avec la syntaxe et la sémantique de Scheme. Une fonctionnalité intéressante qui est absente en Erlang est la capacité d'envoyer une continuation en message. Termite Scheme est implémenté sur le système Gambit Scheme qui offre une façon de sérialiser la plupart des objets Scheme incluant les procédures et les continuations.

La sérialisation de procédures est un outil utile pour implémenter un protocole RPC. En plus des procédures, il est possible de sérialiser des continuations. Une continuation est une structure de donnée qui capture l'état d'un processus. Donc il est possible de transmettre l'état d'un processus sur un autre nœud.

L'implémentation originale de Termite avait certaines limitations lors de la sérialisation des procédures et des continuations. Dans le cas interprété, les procédures et les continuations sont transmises sans problème entre les nœuds. Dans le cas compilé, il faut que chaque nœud possède le code compilé des procédures qui sont transmises.

#### 6.2. Communication dans Termite

L'ensemble des données transmis sont sérialisées par la procédure object->u8vector qui prend en paramètre l'objet à sérialiser et optionnellement une procédure transform qui est appellé sur toutes les sous-objets dans l'objet pour personnaliser le processus de sérialisation. Le résultat est un u8vector (vector d'octets).

La sérialisation des de la plupart des objets utilise les bits de poids fort du premier octet pour indiquer le type de l'objet. Le reste des bits du premier est utiliser pour encoder des propriétés de base comme la longueur de l'objet (si la valeur peut être encodé avec ces bits). La sérialization du vecteur #(1 2 3) est représenté par ces 4 octets #x23 #x51 #x52 #x53. Le premier octet indique que c'est un type vector de longueur 3, les autres octets représente les nombre 1, 2 et 3. La sérialisation d'une procédure contient le nom de celle-ci et un entier qui l'identifie. La figure 6.1 montre un exemple de la sérialisation d'une procédure compilée. Cette représentation est conçue pour être compacte et éviter la redondance dans les données. En plus, elle est indépendante de l'architecture de la machine.

```
> (##subprocedure-id sqrt)
0
> (##subprocedure-parent sqrt)
##
/ (procedure #2 sqrt>

/ (##subprocedure-parent-name sqrt)
// (sqrt)

/ (object->u8vector sqrt)
// (409003 4 115 113 114 116)
// (409003 5 sqrt)
// (subprocedure with id=0 Gambit version)
```

Fig. 6.1. La représentation du résultat de la sérialisation en u8vector de la procédure sqrt.

### 6.3. *Hook* des procédures inconnues

Le système Termite permet la migration de code compilé avec les procédures object->u8vector et u8vector->object. Ces procédures effectuent respectivement la sérialisation et la désérialisation. La sérialisation d'une procédure est encodée par le nom de la procédure et un entier qui l'identifie (id).

Le nom qualifié de la procédure (i.e. qui contient un #) est composé de l'espace de nom et du nom court. La procédure \_hamt#make-hamt est dans l'espace de nom \_hamt et à un nom court make-hamt. L'espace de nom dans un module qui est hébergé correspond au module-ref qui est dans le cas des modules hébergés l'URL du dépôt contenant le code du module.

Dans le processus de désérialisation, le nom de la procédure et le id sont utilisés pour retrouver la procédure. Un *hook* est invoqué si la procédure n'existe pas dans le processus courant. Le but de ce *hook* est de dynamiquement installer et charger le module qui implémente la procédure inconnue.

### 6.4. Exemple de migration de code

Pour montrer les capacités de du système nous avons conçu un scénario de mise à jour de code entre deux nœuds. Un nœud qui exécute l'application compilée et un nœud qui exécute le code qui effectue la mise à jour de l'application sans interrompre le service.

Les deux nœuds ont la même version de Gambit, car la mise à jour de code compilé requiert une version uniforme de Gambit. La représentation des *subprocedure* peut être inconsistante entre les versions de Gambit.

L'application est une horloge programmable écrite en Termite Scheme qui affiche l'heure dans plusieurs fuseaux horaires. Cette application a un bogue d'affichage volontaire qui se produit lorsque l'horloge passe de 12h59 à 1h00. L'affichage montre 1h009 au lieu de 1h00.

Cette horloge offre un API simple:

- La modification du fuseau horaire est faite en envoyant un message (nombre entier).
- Le message timezone-get permet de récupérer le fuseau horaire courant.
- Le message update-code permet la mise à jour dynamique du code du serveur.
- Tous les autres messages sont rejetés par le serveur.

L'horloge programmable est démarrée sur le nœud, par exemple un raspberry 4. L'heure affichée n'est pas dans le bon fuseau horaire, donc nous utilisons le programme timezone-set.scm de la figure 6.4 pour configurer le bon fuseau horaire. Par exemple, pour assigner le fuseau 4 nous invoquons le programme comme suit: gsi timezone-set.scm 4.

L'horloge est maintenant dans le fuseau horaire 4. Une nouvelle version de l'horloge programmable est disponible. Le service ne doit pas être interrompu. Par commodité l'horloge supporte un message qui permet la mise à jour du code qui est (update-code).

Le programme updater.scm de la figure 6.4 permet d'envoyer la nouvelle version de l'horloge programmable. La mise à jour est faite en envoyant une procédure ou une continuation qui contient la logique ou une continuation (comme dans la figure 2.8) qui contient la logique. Dans ce cas c'est une procédure qui est envoyée pour mettre à jour le horloge programmable.

La procédure envoyée provient du module github.com/frederichamel/termite-clock@v2 qui est la nouvelle version de l'horloge. L'espace de nom de ce module est github.com/frederichamel/termite-clock@v2#. Le nom de la procédure est clock-thread-loop.

La sérialisation de la procédure contient le nom de la procédure incluant l'espace de nom. Le nœud Termite qui roule l'application de l'horloge programmable a configuré l'installation automatique des modules. Même si la procédure n'existe pas sur le nœud Termite de l'horloge programmable le système va l'installer, le compiler et le charger dynamiquement.

```
;; clock-app.scm
(import (termite))
(import (github.com/frederichamel/termite-clock @v1))
;; Should be integrated in the system.
(##unknown-procedure-handler-set!
 (lambda (name id)
   (let* ((name-str (##symbol->string name))
           (proc/ns (##reverse-string-split-at name-str #\#)))
     (and (##pair? (##cdr proc/ns))
           (let ((mod-name (##last proc/ns)))
             (##load-module (##string->symbol mod-name))
             (let ((proc (##get-subprocedure-from-name-and-id name id)))
              proc))))))
(define node (make-node "b.local" 3000))
(define (start)
 (node-init node)
 (display "033[H\\033[J");; clean screen
 (clock-start 'clock-app)
 (wait-for (resolve-service 'clock-app)))
(start)
```

**Fig. 6.2.** Le code du serveur qui configure la *hook* qui résout les références à des procédures inconnues. C'est effectué avec la procédure ##unknown-procedure-handler-set!.

#### 6.5. Conclusion

Ce chapitre présente le mécanisme de diffusion des modules utilisés dans la migration de code. L'exemple de l'horloge montre une application de mise à jour dynamique du code qui est possible grâce au mécanisme de diffusion du code. Notre implémentation de ce système permet l'installation de la nouvelle version d'un module qui répare un bug dans l'application termite-clock dans arrêter l'application.

Ce mécanisme est utile pour mettre à jour un serveur évolutif sans l'interrompre. Notre approche permet la diffusion de modules entre les nœuds d'un système distribué. Nous évaluons les performances de notre système dans le prochain chapitre.

```
(define (clock-thread-loop timezone)
 (let tick ()
   (let* ((now (time->seconds (current-time)))
           (next (* 0.5 (floor (+ 1 (* 2 now)))));; next 1/2 second
          (to (seconds->time next)))
     (let wait ()
       (recv
          ((from tag timezone) (where (integer? timezone))
          (! from (list tag 'ok)) ;; send confirmation
          (clock-thread-loop timezone))
          ((from tag ('update-code k))
          (! from (list tag 'ok)) ;; send confirmation
          (k timezone))
          ((from tag 'timezone-get)
          (! from (list tag timezone))
          (wait))
          (after to
          (clock-update next timezone)
           (tick)))))))
```

Fig. 6.3. Extrait du code de l'horloge programmable.

```
;; config.scm
(define local (make-node "a.local" 3000)) ;; x86 arch
(define remote (make-node "b.local" 3000)) ;; ARM arch
```

Fig. 6.4. Les applications clients qui interragissent avec l'horloge programmable. Il y a le programme qui modifit le timezone de l'horloge programme dans timezone-set.scm. Il y a le programme de mise à jour de l'horloge programmable dans updater.scm.

# Chapitre 7

## Évaluation

L'originale implémentation de Termite était capable d'envoyer des messages qui contient du code, qui est absent sur le nœud destination, à condition que le code soit interprété. Notre système permet cette transmission dans le contexte compilé. Ce chapitre évalue les performances du système de modules. Notre approche d'évaluation utilise trois programmes de test (benchmarks). Nous avons fait des expérimentations pour comparer les performances de la diffusion de module, que nous avons conçu, dans un contexte compilé avec la diffusion de code interprété déjà présent dans Termite Scheme.

Le but est de prouver que l'utilisation de modules compilés, rendu possible par notre approche, est plus avantageuse au niveau de la performance par rapport à la diffusion de code interprété. Nous avons aussi testé la diffusion des modules entre des nœuds de nature différente (ARM, x86).

### 7.1. Description des expériences

Les expériences exploitent l'installation automatique des modules pour la diffusion. Les performances du système de module sont mesurées en utilisant le temps de téléchargement, de compilation et de chargement des modules. Les modules pour tester les capacités de diffusion de code sont basés sur certains benchmarks standard de Scheme présent dans Gambit:

- Puzzle (4K)
- Scheme (40K)
- Compiler (400K)

Nous référons à ces benchmarks par leur taille du code source en octets (4K, 40K et 400K).

Les expériences sont effectuées dans trois scénarios distincts:

- INTERPRETED: Les deux nœuds sont interprétés.
- STEADY-STATE: Les modules sont déjà installés et compilés sur le nœud destination, mais non chargé.
- FIRST-INSTALL: Les modules ne sont pas installés sur le nœud destination.

Les tests de performance sont effectués sur deux nœuds. Le test de RPC consiste à diffuser une tâche sur le nœud générique qui ne connait aucun code qui est diffusé dessus.

La diffusion de code est effectuée 100 fois pour chaque benchmark. Le temps d'exécution du benchmark est paramétré de telle sorte que le temps de la version interprétée du benchmark soit proportionnel à sa taille. Le temps respectif de la version interprétée des benchmarks: Puzzle, Scheme et Compiler sont respectivement dans les ordres de 0.1 seconde, 1 seconde et 10 secondes. La première ligne des figures [7.1] montre cette tendance dans les temps d'exécutions. Notre but est de montrer un lien entre la taille du programme et le temps d'exécution.

## 7.2. Spécification des machines

Les machines sur lesquelles les tests ont été effectués sont:

- $M_{x86/Linux}$  est une machine x86\_64 roulant Linux;
- •  $M_{x86/macOS} \, {\rm est}$  une machine x86\_64 roulant macOS;
- $M_{ARM/Linux}$  est un Raspberry Pi ARM roulant Linux.

Les spécifications détaillées de ces machines sont présentes à l'annexe A. La diversité des machines utilisées montre que la diffusion de code compilé est indépendante de la plateforme et de l'architecture de la machine.

La machine  $M_{x86/Linux}$  est la machine la plus stable numériquement de toutes celles utilisées, car elle a un système de refroidissement au liquide. Les résultats pris sur  $M_{x86/Linux}$  ont une variance plus petite et sont reproductibles.

La machine  $M_{ARM/Linux}$  est la machine la moins performante. Elle est d'une architecture ARM, ce qui permet de tester la transmission de tâche entre des architectures différentes.

#### 7.3. Résultats

Les temps dans les tests sont mesurés en millisecondes (ms). Le programme est exécuté 20 fois, les valeurs extrêmes sont éliminées pour tenir compte des variations de la latence du réseau. Les tables des résultats contiennent la moyenne et l'écart-type de chaque mesure.

La première observation est que pour tous les scénarios le temps du nœud de départ n'a pas d'impact sur le temps RPC total. Cela est attendu puisque la majorité du travail est effectué sur le nœud destination. Les temps les plus grands sont généralement pour  $M_{ARM/Linux}$ . Cela peut être expliqué par temps de transfert qui est plus grand.

Le temps de transfert (la latence réseau et de sérialisation/désérialisation) varie proportionnellement avec la taille des messages. Dans le scénario STEADY-STATE, les messages sont les paramètres de la procédure et le résultat. Dans ce scénario, le temps associé aux transmissions varie de 13-15ms pour  $M_{x86/macOS}$  et de 25-30ms pour  $M_{ARM/Linux}$  (un processeur et une interface réseau moins performants). Les temps mesurés sur le nœud destination sont essentiellement les mêmes.

Dans le scénario INTERPRETED le message contient une représentation du code à exécuter, ce qui est gros pour le 400K. Dans ce scénario, le temps des transmissions varie de 15-83ms pour  $M_{x86/macOS}$  et de 47-411ms pour  $M_{ARM/Linux}$  (encore une fois le temps est affecté par la performance du processeur et l'interface réseau). Le temps de transmission est négligeable par rapport au temps total du RPC. Pour le scénario STEADY-STATE, le temps de transmission est plus important pour le 4K qui est le programme le plus petit. La transmission demande plus de travail que le calcul sur le nœud destination.

### 7.3.1. Comparaison entre les scénarios INTERPRETED et STEADY-STATE

Pour évaluer les performances de notre système, nous pouvons comparer le temps des scénarios INTERPRETED et STEADY-STATE. Le temps RPC total du scénario STEADY-STATE est 22x plus plus petit pour  $M_{x86/macOS}$  et  $M_{ARM/Linux}$  que dans le scénario INTERPRETED pour le 400K. Pour le 4K, les temps d'exécution du RPC total sont de 6x-9x plus petit que dans le cas INTERPRETED. Dans le cas moyen 40K, l'accélération est de 16x-20x plus rapide que le scénario interprété.

## $M_{x86/macOS}$

Temps (ms)	4K	40K	400K
Total pour RPC	$146.4 \pm 0.6$	$966.9 \pm 6.1$	$10463.8 \pm 3.3$
Sur la destination	$131.6 \pm 0.2$	$948.7 \pm 5.9$	$10381.0 \pm 2.7$

## $M_{ARM/Linux}$

Temps (ms)	4K	40K	400K
Total pour RPC	$179.2 \pm 1.6$	$1002.7 \pm 8.1$	$10801.1 \pm 11.0$
Sur la destination	$132.6 \pm 0.7$	$954.6 \pm 0.0$	$10390.5 \pm 2.6$

Fig. 7.1. Les temps le scénario INTERPRETED avec  $M_{x86/macOS}$  ou  $M_{ARM/Linux}$  comme le nœud de départ

## $M_{x86/macOS}$

Temps (ms)	4K	40K	400K
Total pour RPC	$15.5 \pm 0.7$	$48.5 \pm 0.6$	$478.7 \pm 0.6$
Sur la destination	$2.2 \pm 0.0$	$35.2 \pm 0.1$	$463.3 \pm 0.3$

## $M_{ARM/Linux}$

Temps (ms)	4K	40K	400K
Total pour RPC	$26.9 \pm 1.2$	$60.4 \pm 0.6$	$492.5 \pm 0.7$
Sur la destination	$2.2 \pm 0.0$	$35.2 \pm 0.0$	$462.8 \pm 0.3$

Fig. 7.2. Les temps dans le scénario STEADY-STATE avec  $M_{x86/macOS}$  ou  $M_{ARM/Linux}$  comme le nœud de départ

### 7.3.2. Comparaison entre les scénarios INTERPRETED et FIRST-INSTALL

Le scénario FIRST-INSTALL inclut le temps d'installation et de compilation des modules. En comparaison avec le scénario INTERPRETED, une première observation indique que le temps total RPC pour  $M_{x86/macOS}$  et  $M_{ARM/Linux}$  sont 6x-8x fois plus grand pour le bench 4K (le module le plus petit). Cela s'explique par le temps de compilation et d'installation. Le temps d'exécution sur le nœud de destination est 60x plus rapide que dans le cas INTERPRETED.

### $M_{x86/macOS}$

Temps (ms)	4K	40K	400K
Total pour RPC	1208.6	2460.3	148536.2
Sur la destination	2.2	36.1	464.7

## $M_{ARM/Linux}$

Temps (ms)	4K	40K	400K
Total pour RPC	1159.8	2502.0	153272.6
Sur la destination	2.2	37.1	464.1

**Fig. 7.3.** Les temps dans les scénario FIRST-INSTALL avec  $M_{x86/macOS}$  ou  $M_{ARM/Linux}$  comme le nœud de départ

Le temps d'exécution total des programmes de tests exploitant la diffusion de code compilé, nécessitant l'installation et la compilation du module, est plus court que la version interprétée. Le facteur qui prend le plus de temps dans le contexte compilé est l'installation et la compilation des modules diffusés. Suite à une première exécution qui a installé les modules compilés, l'exécution est plus rapide que dans le cas interprété.

Dans le cas où les modules ont déjà été installés et compilés, le temps global d'exécution des programmes de tests est plus rapide dans le cas compilé. Dans ce cas, les modules sont chargés dynamiquement dans le programme de tests lors de la diffusion de code. Les figures [7.2] montrent les temps dans le cas où les modules ont été compilés et les figures [7.1] montrent les temps des modules interprétés. Cela s'explique par le fait qu'il y a moins de données transmises et que l'exécution de code compilé est plus rapide que l'interprétation.

Le temps de transmission des données dans les programmes de test compilés était plus court que dans le cas interprété pour certaines des transmissions, malgré le fait qu'il y a moins de données à transmettre. Cela affecte environ 10% des transmissions et est lié à des facteurs aléatoires du réseau.

#### 7.4. Conclusion

Le temps de diffusion des modules est proportionnel à leurs tailles. Plus un module est gros plus son temps de diffusion est grand. La diffusion de modules compilés est avantagée

lorsque le temps d'exécution de l'appel RPC interprété est plus grand que les temps de compilation et d'installation. Le temps d'exécution compilé lorsque les modules sont déjà installés, mais non chargés est plus rapide que la transmission des modules interprétés. Notre approche de diffusion offre une exécution qui est amortie après la première diffusion de module, c'est-à-dire après que les modules aient été installés et compilés.

# Chapitre 8

### Conclusion

Ce mémoire a présenté un système de module spécialisé pour les systèmes distribués. Il permet la conception d'applications qui exploite la diffusion de modules entre les nœuds. Les appels RPC et la migration de code mobile entre des nœuds de nature différente sont possibles. Chaque module diffusé a un nom unique basé sur l'URL du dépôt de code qui permet de le récupérer. La diffusion se fait par le nom des identifiants qui contient l'URL du module. La façon de nommer les modules dans ce système est similaire à celui du langage de programmation Go.

Nous avons commencé par exposer les limitations du système Termite Scheme par des expérimentations dans plusieurs situations. Dans le contexte purement interprété, la migration fonctionnait correctement même dans le cas ou le nœud de destination ne connait pas le code de l'agent mobile. C'est dans le contexte où les applications de chaque nœud sont compilées que la migration de tâche est un défi, car elle requiert la présence du code compilé de l'agent mobile sur l'ensemble des nœuds qui peuvent avoir des architectures et système d'exploitation différents.

Nous avons exploré plusieurs méthodes de chargement automatique des modules. Le langage Scheme permet le chargement de module à la demande.

Ce qui nous a menés à un constat que le nom des identifiants de module transmit devait être unique au sein du système distribué. Les modules, basés sur R5RS, n'offraient pas la possibilité d'avoir des identifiants uniques.

Nous avons ajouté une forme spéciale à Gambit pour permettre la création de modules. Le projet a mené au système de modules spécialisés pour les systèmes distribués à commencer par des expérimentations avec Termite. Le résultat présent est prometteur, il permet le

déploiement de serveurs sur plusieurs machines d'architecture et de systèmes d'exploitation différents.

Le système Gambit a été amélioré par l'ajout des modules primitifs et aussi des modules R7RS. De nouveaux mécanismes de chargement de modules ont été ajoutés pour garantir l'ordre et le chargement unique de chaque module.

L'installation et la compilation des modules sont effectuées automatiquement à la demande. Les coûts du chargement de module sont amorties après la première installation et compilation d'un module. L'utilisation interprétée de Termite n'utilise pas la compilation et l'installation automatique. La vitesse d'exécution après l'amortissement surpasse la version interprétée. Le facteur d'accélération observé après la première exécution qui installe les modules compilés est approximativement de 75x pour le test de 4K, 459x pour le test de 40K et 33x pour le test de 400K. Le facteur d'accélération est principalement lié au fait que le code compilé est plus rapide que celui interprété. Puisqu'il y a moins de transmission dans le temps compilé, parce que les données sont plus compactes que lorsqu'interprété, le temps de transmission est généralement plus petit. La taille de la sérialisation d'une procédure compilée est environ 400 fois plus petite que sa version interprétée.

L'approche de diffusion des modules est applicable à d'autres langages. Il faut que le langage supporte le chargement dynamique de module et que les procédures soient des objets manipulables comme des données. Il faut aussi que la sérialisation et désérialisation des procédures passe par un encodage qui uniforme et indépendant de la machine. L'information encodée doit contenir l'information du module qui contient la procédure et un identifiant unique de la procédure. Une sérialisation similaire à celle qui est utilisée dans Gambit.

Notre approche de gestion des modules diffère des autres gestionnaires par la gestion des versions des modules. Plusieurs versions d'un module peuvent être installées. La gestion des modules dans Racket (raco) ne permet pas d'installer plusieurs versions des modules. Akku, un autre gestionnaire de modules compatible avec plusieurs implémentations de Scheme à des caractéristiques similaires à raco.

L'implémentation actuelle des modules a quelques éléments à améliorer. Les macros définies dans le contexte d'un module ont des problèmes d'hygiènes lors de l'expansion dans un autre module. Le temps d'installation des modules peut être optimisé. L'opération de mise à jour ne permet pas de mettre à jour les branches qui sont installées.

Les messages d'avertissement (warnings) lors de la compilation des modules sont manquants. Il n'y a pas de message indiquant l'utilisation d'une liaison non définie.

Bref, notre approche de diffusion des modules compilés permet d'avoir une plus grande performance à l'exécution. Cela permet la mise à jour de code d'un nœud distant sans interrompre son service. Cette approche est applicable à d'autres langages. La transmission permet d'avoir une meilleure performance d'exécution. Le prix est le temps d'installation et de compilation du module.

## Références bibliographiques

- TCLTK'96: Proceedings of the 4th Conference on USENIX Tcl/Tk Workshop, 1996 Volume 4, Berkeley, CA, USA, 1996. USENIX Association.
- [2] David M. BEAZLEY, Brian D. WARD et Ian R. COOKE: The inside story on shared libraries and dynamic loading. *Computing in Science and Engineering*, 3(5):90–97, 2001.
- [3] T. Berners-Lee, MIT/LCS, R. FIELDING, U.C. IRVINE, L. MASINTER et Xerox Corporation: Uniform resource identifiers (uri): Generic syntax. https://tools.ietf.org/html/rfc2396, 1998.
- [4] Tyler Bui-Palsulich et Eno Compton: Go reference manual 1.13.5. https://blog.golang.org/using-go-modules, 2019.
- [5] Capturing, et Stefan Funfrocken: Transparent migration of Java-based mobile agents. In Mobile Agents, pages 26–37. Springer-Verlag, 1998.
- [6] Guillaume Cartier et Louis-Julien Guillemette: Jazzscheme: Evolution of a lisp-based development system. In 2010 Workshop on Scheme and Functional Programming, page 50. Citeseer, 2010.
- [7] W. CLINGER, J. REES et et al: Revised<sup>4</sup> report on the Algorithmic Language Scheme. http://people.csail.mit.edu/jaffer/r4rs.pdf, novembre 1991.
- [8] William D CLINGER: Scheme@33. In Celebrating the 50th Anniversary of Lisp, LISP50, pages 7:1-7:5, New York, NY, USA, 2008. ACM.
- [9] Marc FEELEY: Feature-based conditional expansion construct. https://srfi.schemers.org/srfi-0/ srfi-0.html, 1999.
- [10] Marc Feeley et Philip W. Trinder, éditeurs. Proceedings of the 2006 ACM SIGPLAN Workshop on Erlang, Portland, Oregon, USA, September 16, 2006. ACM, 2006.
- [11] Adrian Francalanza et Tyron Zerafa: Code management automation for Erlang remote actors. *In* Jamali *et al.* [15], pages 13–18.
- [12] Guillaume GERMAIN: Concurrency oriented programming in termite scheme. In FEELEY et TRINDER [10], page 20.
- [13] Robert S. Gray: Agent tcl: A flexible and secure mobile-agent system. In Proceedings of the 4th Conference on USENIX Tcl/Tk Workshop, 1996 - Volume 4, TCLTK'96, pages 9–23, Berkeley, CA, USA, 1996. USENIX Association.

- [14] W. Wilson Ho et Ronald A. Olsson: An approach to genuine dynamic linking. *Softw., Pract. Exper.*, 21(4):375–390, 1991.
- [15] Nadeem Jamali, Alessandro Ricci, Gera Weiss et Akinori Yonezawa, éditeurs. Proceedings of the 2013 Workshop on Programming based on Actors, Agents, and Decentralized Control, AGERE!@SPLASH 2013, Indianapolis, IN, USA, October 27-28, 2013. ACM, 2013.
- [16] Guy L. Steele Jr.: Debunking the "expensive procedure call" myth or, procedure call implementations considered harmful or, LAMBDA: the ultimate GOTO. *In* KETCHEL *et al.* [19], pages 153–162.
- [17] Takashi Kato: Implementing r7rs on an r6rs Scheme system. In Scheme and Functional Programming Workshop, SFPW 2014, 2014.
- [18] R. KELSEY, W. CLINGER, J. REES et *et al*: Revised<sup>5</sup> report on the Algorithmic Language Scheme. https://schemers.org/Documents/Standards/R5RS/r5rs.pdf, février 1998.
- [19] James S. KETCHEL, Harvey Z. KRILOFF, H. Blair BURNER, Patricia E. CROCKETT, Robert G. HERRIOT, George B. HOUSTON et Cathy S. KITTO, éditeurs. Proceedings of the 1977 annual conference, ACM '77, Seattle, Washington, USA, October 16-19, 1977. ACM, 1977.
- [20] A. LUKIĆ, N. LUBURIĆ, M. VIDAKOVIĆ et M. HOLBL: Development of multi-agent framework in JavaScript. In ICIST 2017 Proceedings Vol.1, pages 261–265, 2017.
- [21] Stefan M, Raymond BIMAZUBUTE et Herbert STOYAN: Mobile intelligent Agents in Erlang. In Fourth International ICSC Symposium on ENGINEERING OF INTELLIGENT SYSTEMS (EIS 2004), 2004.
- [22] Michał Piotrowski et Wojciech Turek: Software agents mobility using process migration mechanism in distributed erlang. *In Proceedings of the Twelfth ACM SIGPLAN Workshop on Erlang*, Erlang '13, pages 43–50, New York, NY, USA, 2013. ACM.
- [23] PLT INC.: Racket scheme. https://racket-lang.org/, 2020. Accessed: 2020-02-24.
- [24] Tom Preston-Werner: Semantic versioning 2.0.0. https://semver.org/spec/v2.0.0.html, 2013. Accessed: 2020-02-27.
- [25] A. SHIN, J. COWAN, ARTHUR A. GLECKLER et *et al*: Revised<sup>7</sup> report on the algorithmic language scheme. https://small.r7rs.org/attachment/r7rs.pdf, juillet 2013.
- [26] MICHAEL SPERBER, R. KENT DYBVIG et et al: Revised<sup>6</sup> report on the Algorithmic Language Scheme. http://www.r6rs.org/final/r6rs.pdf, septembre 2007.
- [27] Eijiro Sumii: An implementation of transparent migration on standard scheme. In Department of Computer Science, Rice University, 2000.
- [28] Dimitris Vyzovitis: Gerbil scheme. https://cons.io/, 2020. Accessed: 2020-02-21.
- [29] Göran Weinholt: Akku package management made easy. https://akkuscm.org/, 2019. Accessed: 2020-02-21.

## Annexe A

### Information des environnement de test

Architecture: x86\_64

CPU op-mode(s): 32-bit, 64-bit

CPU(s): 4

Thread(s) per core: 1

Core(s) per socket: 4

Vendor ID: GenuineIntel

Model name: Intel(R) Core(TM) i7-7700K CPU @ 4.20GHz

CPU MHz: 4200.000 CPU min MHz: 800.0000

Storage: 216GB (NVME)

RAM: 16GB Swap: 16GB

C Compiler gcc (Debian 6.3.0-18+deb9u1) 6.3.0 20170516

Ethernet Speed 1Gbps

Fig. A.1. La spécification de la machine arctic qui est utilisé comme nœud de destination dans l'ensemble des tests. Cette machine, nommé  $M_{x86/Linux}$  est refroidit au liquide.

Architecture: armv7l

Byte Order: Little Endian

CPU(s): 4

Thread(s) per core: 1

Core(s) per socket: 4

Vendor ID: ARM

Model name: Cortex-A72

CPU max MHz: 1500.0000

CPU min MHz: 600.0000

OS: Linux tictoc 4.19.66-v7l+ #1253 SMP

Hostname: tictoc.iro.umontreal.ca

Storage: 26GB (sdcard)

RAM: 2GB

Swap: 2GB

C Compiler gcc (Raspbian 8.3.0-6+rpi1) 8.3.0

Ethernet Speed 1Gbps

**Fig. A.2.** La spécification du CPU du Raspberry Pi $M_{ARM/Linux}$ utilisé dans les tests.

Architecture: x86\_64

CPU(s): 12

Thread(s) per core: 2

Core(s) per socket: 6

Model name: Intel(R) Core(TM) i7-8700B CPU @ 3.20GHz

OS: Darwin Kernel Version 19.2.0

Hostname: gambit.iro.umontreal.ca

Storage: 1TB (SSD)

RAM: 32GB

Network Speed: 1Gbps

Fig. A.3. La spécification de la machine  $M_{x86/macOS}$  qui roule mac OS.